ISEN MÉDITERRANÉE | L'ÉCOLE DES INGÉNIEURS DU NUMÉRIQUE

Titre ingénieur - Ingénieur diplômé de l'institut supérieur de l'électronique et du numérique
Yncréa Méditerranée

Promotion e-Santé 2025 - 2026

Application du Deep Learning à la fiabilisation et au tri automatique de signaux intracérébraux stéréo-électroencéphalographiques

DI GIOVANNI Célian

Tuteur académique : Monsieur Alain Loussert
Directeur de stage : Monsieur Olivier David
Encadrant scientifique : Monsieur Francesco Borra

Institut de Neurosciences des Systèmes

Abstract

This master thesis investigates automated artifact detection in stereo-electroencephalography (sEEG) signals recorded during intracerebral electrical stimulation. Conducted at the Institut des Neurosciences et Systèmes (INSERM UMR 1106) within the Brain Stimulation Group, this work tackles the challenge of screening over 100,000 channels, representing nearly 70 hours of event-locked physiological signals. A robust data preprocessing pipeline was developed, featuring signal resampling and activity index stratification to build balanced datasets. Three modeling strategies were implemented on a high-performance computing cluster: Convolutional Neural Networks, Principal Component Analysis, and Fully Connected Autoencoders with dedicated normalization layers. The models were benchmarked against a curated human-validated dataset. Results demonstrate that deep non-linear representations outperform linear projections in isolating stimulation artifacts, optimizing clinical data workflows and paving the way for automated real-time neurophysiological signal screening applications.

Keywords

sEEG, Artifact Detection, AI, Deep Learning, CNN, Autoencoders, PCA, e-Health, Research

Engagement personnel

« Je soussigné, Célian Di Giovanni, certifie que le contenu de ce rapport est le résultat de mon travail personnel. Je certifie également que les données, raisonnements, et conclusions empruntées à la littérature existante sont exactement rapportés, cités et mentionnés, en particulier dans la partie Référence. Je certifie finalement que ce rapport de stage, totalement ou partiellement, n'a jamais été évalué auparavant, et n'a jamais été édité ».

21/08/2026
Toulon



Remerciements

Je tiens à exprimer ma profonde gratitude à l'ensemble des personnes qui m'ont accompagné tout au long de ce stage de fin d'études au sein de l'Institut des Neurosciences et Systèmes (INS-UMR 1106).
J'adresse mes plus sincères remerciements à mon tuteur de stage, **Monsieur Olivier David**, pour sa disponibilité, ses conseils, sa confiance et son encadrement bienveillant tout au long de mes recherches et de la conception des architectures.
Je remercie particulièrement **Monsieur Francesco Borra** pour son accompagnement, ses précieux conseils ainsi que sa patience tout au long de ce stage.
Mes remerciements s'adressent également à l'ensemble des membres de l'équipe **Brain Stimulation Group** et la **direction du laboratoire** pour leur accueil, le partage de leur expertise et la mise à disposition des infrastructures de calcul haute performance. Enfin, je remercie mon tuteur académique le **Professeur Alain Loussert**, pour son accompagnement en option e-santé de mon cursus ingénieur.

Sommaire

Abstract.....1
Engagement personnel.....2
Remerciements.....3
Sommaire.....4
Table des Sigles et Abréviations.....8
Introduction.....10
Chapitre 1 : Présentation de l'Organisme d'Accueil et du Service.....13
1. Présentation de l'organisme d'accueil : l'INSERM et l'INS (UMR 1106).....13
L'institut National de la Santé et de la Recherche Médicale (INSERM).....13
L'institut des Neurosciences et Systèmes (INS).....13
2. Position et rôle de l'équipe d'accueil : l'équipe Brain Stimulation Group.....15
Thématiques de recherche et projets de l'équipe.....15
Positionnement et rôle de l'ingénieur stagiaire.....15
3. Enjeux spécifiques liés au stage.....16
Enjeux scientifiques et cliniques.....16
Enjeux technologiques et passage à l'échelle.....16
Chapitre 2 : Description de la Mission et des Travaux Réalisés.....18
1. Problématique scientifique et neurophysiologique détaillée.....18
La stéréo-électroencéphalographie (sEEG) et la stimulation électrique intracérébrale. 18
Figure 2.1 : Représentations 3D d'implantations stéréotaxique d'électrodes sEEG ciblant des structures corticales et sous-corticales.....18
Typologie des signaux : distinguer l'activité neuronale des artéfacts.....19
Figure 2.2 : Morphologie typique d'un potentiel évoqué cortico-cortical. Après l'artéfact de stimulation (ligne rouge), le signal physiologique émerge.....19
Figure 2.3 - Profil temporel d'un canal physiologique valide ("Good") sur 10 stimulations successives : ligne de base pré-stimulation stable (-100 à 0 ms), artéfact d'impulsion électrique direct circonscrit entre 0 et 10 ms (traits rouge et vert), suivi de la dynamique neuronale caractéristique avec l'émergence des composantes N1 (pic précoce) et N2 (onde lente tardive) . (Note : L'axe des ordonnées ne représente pas l'amplitude naturelle en microvolts, les signaux ayant fait l'objet d'une normalisation par division par l'écart-type).....20
Figure 2.4 - Profil temporel d'un canal corrompu : présence d'un bruit périodique pré-stimulation, suivie d'un effondrement brutal de tension post-impulsion et d'une saturation prolongée rendant le signal inexploitable. (Note : L'axe des ordonnées est normalisé par division par l'écart-type, de manière identique à la Figure 2.1).....21
Synthèse opérationnelle.....21
2. Etat de l'art scientifique et technique.....22
Les fondations par apprentissage automatique classique.....22
Le système expert et déterministe préexistant.....22
3. Environnement de développement et architecture de calcul.....24
Le serveur d'équipe : point d'ancrage et prototypage.....24

Le cluster de l'INS : passage à l'échelle et calcul distribué....24
Figure 2.5 : Schéma environnement de développement....25
4. Ingénierie des données (Data Pipeline)....26
Exploration, extraction, et harmonisation des signaux....26
Figure 2.6 : Exemple d'une fenêtre (isolée) de stimulation d'un canal enregistré 26
Stratification par l'activité Post-Stimulation ()....27
Figure 2.7 : Résumé visuel de la démarche de stratification....28
5. Modélisation par apprentissage automatique....29
Référence exploratoire : l'Analyse en Composantes Principales (PCA)....29
Classification supervisée : réseaux de neurones convolutifs (CNN)....31
Figure 2.8 : Résumé de l'architecture du CNN retenu....33
Approche avancée : autoencodeurs multi-tâches (AE)....34
Figure 2.9 : Résumé de l'architecture globale de l'un des Autoencodeurs développé....36
Chapitre 3 : Résultats, Analyse Comparative et Retombées scientifiques....37
1. Méthodologie d'évaluation et Vérité Terrain....37
Constitution d'un dataset de vérité terrain....37
Figure 3.1 : Exemple d'inspection visuelle d'un canal patient pour la validation de la Vérité Terrain....37
Topologie des données et séparation Train/Test....38
Choix des métriques de classification....38
2. Limites de l'approche linéaire de référence (PCA)....39
Un espace latent non séparable....39
L'impasse de l'erreur de reconstruction....39
Figure 3.2 : Séparation de la zone d'activité d'index la plus confuse....40
Figure 3.3 : Histogramme de la reconstruction d'erreur : Ordonnées = nombre de canaux en échelle logarithmique / Abscisses = erreur de reconstruction entre 0 et 1....41
3. La supériorité de la classification supervisée (CNN)....42
Dynamique d'apprentissage et prévention du surajustement....42
Figure 3.4 : Courbe de Loss de l'architecture de CNN retenue....42
Performances quantitatives globales et confiance prédictive....43
Validation neurophysiologique sur la Vérité Terrain....43
Figure 3.5 : Matrices de confusion symbolisant la différence entre la classification CNN et la classification déterministes déjà existante....44
4. Apports de l'Autoencodeur : Modélisation générative et Séparabilité....45
Validation de la capacité générative....45
Une séparabilité accrue de l'espace latent....45
Une polarisation extrême des probabilités....46
Figure 3.6 : Histogramme de la distribution des probabilités....46
Figure 3.7 : Séparation en 2D de l'autoencodeur....46
Performances de classification sur la Vérité terrain....47
Figure 3.8 : Matrice de confusion de l'Autoencoder sur l'échantillon de Vérité Terrain....47
5. Bilan comparatif....48

Synthèse des approches évaluées..... 48
Préconisations technologiques et perspectives de déploiement.....48
Chapitre 4 : Gestion de Projet.....49
1. Organisation du projet et parties prenantes..... 49
Figure 4.1 : Matrice RACI - Projets IA - Equipe Brain Stimulation Group.....50
2. Décomposition du projet (WBS) en Lots..... 51
Figure 4.2 : Schéma raccourci du WBS..... 51
3. Planification et écarts temporels (Prévisionnel vs Réel)..... 52
Figure 4.3 : Diagramme de Gantt comparatif prévisionnel vs réel : extrait de deux lots, en gris la prévision et en jaune la réalité terrain..... 52
Analyse du Chemin Critique et des Écarts Temporels..... 52
4. Analyse des blocages et gestion des risques..... 53
Saturation matérielle et limites d'infrastructure (Ressources Serveur/RAM) :..... 53
Qualité des données et bruit de labellisation.....53
Courbe d'apprentissage théorique (Modélisation PCA)..... 54
Chapitre 5 : Bilan Personnel et Professionnel..... 55
1. Bilan technique et scientifique (Hard skills).....55
Ingénierie des données et traitement du signal biomédical..... 55
Modélisation en Intelligence Artificielle et Deep Learning..... 55
Infrastructures de calcul et bonnes pratiques de développement..... 56
2. Bilan humain et méthodologique (Soft Skills).....56
Autonomie et gestion de la complexité.....56
Communication scientifique et travail collaboratif..... 57
3. Perspectives d'évolution et projet professionnel..... 57
Une vocation confirmée pour l'IA appliquée à la neurophysiologie.....57
Deux trajectoires envisagées : Recherche et industrie..... 57
Conclusion.....59
Bibliographies et Sources.....61
Annexes..... 63
1. Aperçus matrice des risques et WBS assemblé..... 63
Figure A.1 : Matrice des risques.....63
FIgure A.2 : Aspect WBS assemblé..... 63
2. Extrait du pipeline (script python) de traitement de données et Création des datasets... 64
Figure A.3 : Fonction représentant l'algorithme de stratification dynamique : Segmentations en intervalles, échantillonnage équilibré et compensation des classes.....64
3. Quelques aperçus d'autres "Bad_channels"..... 65
Figure A.4 : Artéfacts de nature biophysique et morphologique. En haut : décharge capacitive lente masquant le signal. En bas : faux-semblant matériel imitant l'allure d'un potentiel évoqué.....65
Figure A.5 : Artéfacts de nature matérielle. En haut : contamination par un bruit périodique continu. En bas : saturation sévère de l'amplificateur avec décrochage de tension. (Note : L'axe des ordonnées est normalisé par division par l'écart-type, ne pas tenir compte de la couleur verte du titre).....66
4. Utilisation de l'IA.....67

Prise en main de l'infrastructure et assistance au développement..... 67
Partenaire de réflexion stratégique et d'architecture..... 67
Support à la communication scientifique et à la rédaction..... 68
Regard critique et limites technologiques..... 68
5. Analyse DDRSE..... 69
Analyse des impacts environnementaux..... 69
Analyse des impacts sociaux : l'IA comme levier de réallocation médicale..... 70
Analyse éthique et responsabilité algorithmique..... 70
Analyse des impacts économiques..... 71
6. Auto-évaluation des compétences..... 72

Table des Sigles et Abréviations

sEEG : Stéréo-Électroencéphalographie

CCEP : Cortico-Cortical Evoked Potentials (Potentiels Évoqués Cortico-Corticaux)

INS : Institut des Neurosciences et Systèmes

INSERM : Institut National de la Santé et de la Recherche Médicale

UMR : Unité Mixte de Recherche

HPC : High-Performance Computing (Calcul Haute Performance)

SLURM : Simple Linux Utility for Resource Management

CNN : Convolutional Neural Network (Réseau de Neurones Convolutif)

PCA : Principal Component Analysis (Analyse en Composantes Principales)

SVD : Singular Value Decomposition (Décomposition en Valeurs Singulières)

FCAE : Fully Connected Autoencoder (Autoencodeur Entièrement Connecté)

AMU : Aix-Marseille Université

CNRS : Centre National de la Recherche Scientifique

AP-HM : Assistance Publique - Hôpitaux de Marseille

EEG : Électroencéphalographie

TVB : The Virtual Brain

RAM : Random Access Memory (Mémoire Vive)

BCE : Binary Cross-Entropy (Entropie Croisée Binaire)

AE : Autoencodeur

MSE : Mean Squared Error (Erreur Quadratique Moyenne)

TP : Vrais Positifs (True Positives)

TN : Vrais Négatifs (True Negatives)

FP : Faux Positifs (False Positives)

FN : Faux Négatifs (False Negatives)

PoC : Proof of Concept (Preuve de Concept)

IA : Intelligence Artificielle

RACI : Réalisateur, Approbateur, Consulté, Informé

WBS : Work Breakdown Structure (Organigramme des Tâches)

ISEN : Institut Supérieur de l'Électronique et du Numérique

Introduction

L’exploration fonctionnelle du cerveau humain et la compréhension des réseaux neuronaux complexes constituent l’un des défis majeurs des neurosciences modernes et de l’ingénierie biomédicale. Dans le cadre du bilan pré-chirurgical des épilepsies pharmaco-résistantes, la stéréo-électroencéphalographie (sEEG) s'impose aujourd'hui comme une technique électrophysiologique de référence. Grâce à l'implantation d'électrodes intracérébrales multi-contacts au plus profond des structures corticales et sous-corticales, la sEEG offre une résolution spatio-temporelle inégalée pour cartographier les zones épileptogènes et sonder la connectivité fonctionnelle cérébrale.

Au-delà de l'enregistrement passif de l'activité cérébrale spontanée, les protocoles cliniques et de recherche recourent fréquemment à la stimulation électrique intracérébrale directe. En injectant des impulsions électriques calibrées à travers des paires de contacts ciblées, les cliniciens et chercheurs peuvent sonder la réactivité locale du cortex et mesurer la propagation des potentiels évoqués cortico-corticaux (CCEP) *[3]*. Ces protocoles de stimulation permettent ainsi de modéliser les réseaux anatomiques et fonctionnels sous-jacents.

Toutefois, l'application d'un courant électrique au sein du parenchyme cérébral engendre un phénomène physique indésirable mais inévitable : l'artéfact de stimulation. Cet artéfact, d'amplitude souvent très largement supérieure aux signaux physiologiques sous-jacents, sature et déforme les enregistrements sur les canaux adjacents ou distaux selon les propriétés de diffusion des tissus. Ce défi méthodologique est d'autant plus critique qu'il s'inscrit dans le cadre du projet collaboratif international F-TRACT *[2][6]*. Cette initiative vise à construire un atlas probabiliste de la connectivité cérébrale en centralisant les données sEEG de multiples hôpitaux *[2]*. La dimension multicentrique implique une hétérogénéité structurelle massive des enregistrements, acquis sur des amplificateurs médicaux de constructeurs distincts, avec des fréquences d'échantillonnage disparates et selon des protocoles propres à chaque centre *[4][5]*. Face à cette base regroupant plus de 1300 patients et représentant plus de 13 millions de canaux enregistrés, le tri manuel de ces signaux par des experts cliniciens devient une tâche matériellement très chronophage et sujette à une forte variabilité inter-observateur.

C'est à cette intersection précise entre un besoin clinique critique et un verrou méthodologique majeur que s'inscrit ce projet de fin d'études d'ingénieur en spécialité e-santé, réalisé au sein de l'équipe Brain Stimulation Group à l'Institut des Neurosciences et Systèmes (INS - INSERM UMR 1106). **La problématique centrale de ce travail est d'automatiser, de fiabiliser et d'accélérer la classification des canaux sEEG stimulés afin d'isoler automatiquement les signaux exploitables (« Good ») des signaux corrompus par des artéfacts majeurs (« Bad »), tout en garantissant un passage à l'échelle sur des volumes massifs de données.**

Pour lever ce verrou, la démarche adoptée a combiné ingénierie des données, calcul haute performance et modélisation par intelligence artificielle :

1. **Une phase d'ingénierie des données et de prétraitement :** Extraction, ré-échantillonnage par interpolation et conception d'un algorithme de stratification avancée basé sur l'Index d'Activité des canaux pour construire des jeux d'apprentissage et de test parfaitement équilibrés et représentatifs.
2. **Le déploiement sur cluster de calcul distribué (HPC / Slurm) :** Optimisation des pipelines d'entraînement pour traiter des volumes massifs de données sans goulot d'étranglement mémoire.
3. **Le développement et le benchmark de trois approches complémentaires :**
    - Une approche supervisée par apprentissage profond via des réseaux de neurones convolutifs (CNN) pour capturer les motifs temporels caractéristiques ;
    - Une approche linéaire non supervisée de référence par Analyse en Composantes Principales (PCA / SVD) ;
    - Une approche non linéaire par Autoencodeur entièrement connecté (FCAE) intégrant des couches de normalisation spécifiques pour évaluer la séparabilité dans l'espace latent.
4. **Une validation rigoureuse :** Confrontation systématique des performances sur un jeu de données de référence spécifiquement validé manuellement (vérité terrain).

Ce rapport s'articule autour de cinq chapitres principaux :

- Le **Chapitre 1** présente l'organisme d'accueil (INSERM / INS), l'équipe Brain Stimulation Group et les enjeux scientifiques et médicaux du stage

- Le **Chapitre 2** détaille la démarche méthodologique, l'ingénierie du pipeline de données, le benchmark des outils et la conception des trois architectures d'IA.
- Le **Chapitre 3** expose les résultats quantitatifs obtenus, l'analyse comparative critique des modèles et les retombées concrètes pour le laboratoire.
- Le **Chapitre 4** décrit le cadre de gestion de projet d'ingénieur (WBS, planification de Gantt et gestion des risques).
- Le **Chapitre 5** dresse le bilan personnel et l'auto-évaluation des compétences d'ingénieur acquises durant cette expérience.

Enfin une conclusion générale synthétisera les apports de ces travaux et ouvrira sur les perspectives d'intégration en temps réel dans les protocoles de recherche bio-médicale.

Chapitre 1 : Présentation de l'Organisme d'Accueil et du Service

1. Présentation de l'organisme d'accueil : l'INSERM et l'INS (UMR 1106)

L'institut National de la Santé et de la Recherche Médicale (INSERM)

Fondé en 1964, l'INSERM est le seul organisme public de recherche français entièrement dédié à la santé humaine. Placé sous la double tutelle du ministère de la Santé et de la Prévention et du ministère de l'Enseignement supérieur et de la Recherche, il rassemble plus de 15 000 chercheurs, ingénieurs, techniciens et personnels hospitalo-universitaires.

La mission fondamentale de l'INSERM s'articule autour de trois piliers complémentaires :

- La **recherche fondamentale** pour décrypter les mécanismes du vivant ;
- La **recherche translationnelle** pour transférer les découvertes scientifiques vers le lit du patient ;
- La **santé publique** et **l'épidémiologie** pour éclairer les décisions médicales et sociétales.

L'institut des Neurosciences et Systèmes (INS)

L'Institut des Neurosciences et Systèmes (UMR 1106) est une unité mixte de recherche sous la double tutelle de l'**INSERM** et d'**Aix-Marseille Université (AMU)**. Implanté sur le campus santé de La Timone à Marseille, l'institut constitue un pôle d'excellence interdisciplinaire dédié à l'étude de la dynamique des réseaux cérébraux, de la neurophysiologie computationnelle et des pathologies neurologiques.

L'institut se structure autour de plusieurs indicateurs et atouts majeurs :

- **Un collectif pluridisciplinaire d'envergure :** L'INS rassemble près d'une **centaine de membres** : chercheurs statutaires (INSERM, CNRS), enseignants-chercheurs universitaires, cliniciens de l'AP-HM, ingénieurs de recherche, post-doctorants, doctorants, stagiaires et étudiants. Cette diversité de profils favorise un croisement permanent entre médecine, physique, mathématiques appliquées et science des données.
- **Une organisation en équipes thématiques :** Les activités de recherche sont réparties entre **cinq équipes scientifiques** spécialisées, soutenues par des plateformes technologiques de pointe (plateformes d'électrophysiologie, de magnétoencéphalographie/EEG haute résolution et d'infrastructures de calcul intensif).
- **Un rayonnement international et de grands programmes de recherche :** L'INS joue un rôle moteur dans des initiatives scientifiques majeures à l'échelle mondiale, notamment dans le développement de la plateforme de modélisation cérébrale **The Virtual Brain (TVB)** et les programmes européens du consortium **EBRAINS / Human Brain Project**.
- **Une forte production scientifique :** Le laboratoire génère chaque année plusieurs dizaines de publications dans des revues internationales de référence (*Brain*, *NeuroImage*, *Science Advances*, *Nature Communications*).
- **Un ancrage hospitalier direct (AP-HM) :** Grâce à sa collaboration étroite et quotidienne avec le service d'épileptologie et de neurophysiologie clinique de l'Hôpital de La Timone, l'institut dispose de bases de données longitudinales uniques, regroupant des enregistrements de plus d'une **centaine de patients explorés par sEEG**, représentant des **dizaines de milliers d'heures de signaux et des millions de canaux enregistrés**.

Cette concentration d'expertises cliniques, d'outils de modélisation et de volumes de données massifs fait de l'INS un environnement privilégié pour concevoir et valider des architectures d'intelligence artificielle appliquées à la neurophysiologie.

2. Position et rôle de l'équipe d'accueil : l'équipe Brain Stimulation Group

Thématiques de recherche et projets de l'équipe

Mon stage s'est déroulé au sein de l'équipe **Brain Stimulation Group**, spécialisée dans l'étude des réponses cérébrales à la stimulation électrique directe et la cartographie fonctionnelle de la connectivité corticale.

Les axes scientifiques majeurs de Brain Stimulation Group couvrent :

- **La cartographie de la connectivité cortico-corticale :** Mesure et modélisation des potentiels évoqués cortico-corticaux (CCEP) induits par des impulsions électriques locales à basse ou haute fréquence ;
- **La modélisation biophysique des réseaux neuronaux :** Compréhension des mécanismes de propagation du signal au sein de la matière grise et blanche ;
- **Le développement d'outils computationnels :** Création de pipelines logiciels pour standardiser, nettoyer et analyser de larges cohortes d'enregistrements sEEG multi-patients.

Positionnement et rôle de l'ingénieur stagiaire

Au sein de l'équipe Brain Stimulation Group, mon rôle s'est situé à l'interface directe entre l'**ingénierie des données massives / intelligence artificielle** et la **neurophysiologie clinique**.

Sous la responsabilité scientifique de Monsieur Olivier David et l'encadrement technique au quotidien de Monsieur Francesco Borra, post-doctorant, mes missions ont consisté à concevoir, développer et valider de manière autonome une chaîne complète de traitement automatisé pour classifier les canaux de stimulation sEEG. Ce travail s'inscrit dans un besoin opérationnel direct de l'équipe : accélérer et fiabiliser la préparation des jeux de données utilisés pour les recherches en connectivité cérébrale.

3. Enjeux spécifiques liés au stage

Enjeux scientifiques et cliniques

L'analyse des signaux sEEG stimulés constitue une étape préalable indispensable à la modélisation des réseaux fonctionnels. Cependant, chaque impulsion électrique appliquée sur un contact d'électrode génère une perturbation physique sur les canaux (artéfact de volume conduction, saturation de l'amplificateur, dérive de ligne de base).

L'enjeu scientifique est d'isoler avec une précision maximale les canaux portant une réponse physiologique authentique (« Good ») de ceux dont le signal est inexploitable ou faussé par un artéfact physique (« Bad »). Un mauvais tri fausse les matrices de connectivité cérébrale et biaise les modèles computationnels ultérieurs.

Enjeux technologiques et passage à l'échelle

Historiquement, la détection des artéfacts au sein de l'équipe Brain Stimulation Group reposait sur un système expert heuristique développé par Francesco Borra. Cette méthode formulait la classification selon une conjonction stricte de 11 critères déterministes combinant traitement du signal classique (filtrage butterworth 30 Hz, dérivée premières), régressions statistiques de Theil-Sen sur la durée d'artéfact, et seuillage de saturation.

Bien que rigoureuse sur le plan théorique, cette approche présentait plusieurs limites opérationnelles face à la montée en charge des données :

- **Sensibilité et rigidité des seuils :** l'obligation de valider simultanément les 11 critères rendait l'algorithme sensible aux cas limites, entraînant le rejet de signaux physiologiques valides.
- **Complexité calculatoire :** l'extraction séquentielle de ces indicateurs statistiques sur des cohortes massives représentait un coût de calcul important.

Besoins d'adaptabilité : les disparités morphologiques inter-patients et le bruit spécifique aux différents centres d'acquisition nécessitaient un système capable d'apprendre des représentations intrinsèques robustes. Face à la base de données du projet collaboratif f-tract *[2][6]*, regroupant

plus de 1300 patients issus de plus de 20 centres hospitaliers et contenant plus de 13 millions de canaux d'enregistrements de stimulations cérébrales, les enjeux d'ingénierie confiés lors de ce stage étaient donc :

- **D'automatiser l'extraction et la standardisation des signaux** à grande échelle via un pipeline de données optimisé.
- **De concevoir et benchmarker des architectures d'intelligence artificielle** (CNN, PCA, Autoencodeurs) capables d'extraire directement des caractéristiques discriminantes des séries temporelles sEEG.
- **De déployer ces entraînements sur le cluster de calcul distribué** (HPC / Slurm) du laboratoire pour garantir l'efficacité computationnelle et la scalabilité des analyses.

Chapitre 2 : Description de la Mission et des Travaux Réalisés

1. <u>Problématique scientifique et neurophysiologique détaillée</u>

La stéréo-électroencéphalographie (sEEG) et la stimulation électrique intracérébrale

La stéréo-électroencéphalographie (sEEG) est une technique d'exploration invasive utilisée dans l'évaluation pré-chirurgicale des patients souffrant d'épilepsie réfractaire. Des électrodes multi-contacts (généralement 10 à 18 contacts par tige) sont implantées stéréotaxiquement dans les structures cérébrales profondes et corticales ciblées.

Au-delà de l'enregistrement de l'activité spontanée, des impulsions électriques brèves (courant continu ou biphasique) sont injectées entre deux contacts adjacents pour sonder l'excitabilité corticale et cartographier les réseaux fonctionnels à travers l'analyse des potentiels évoqués cortico-corticaux (CCEP pour *Cortico-Cortical Evoked Potentials*).

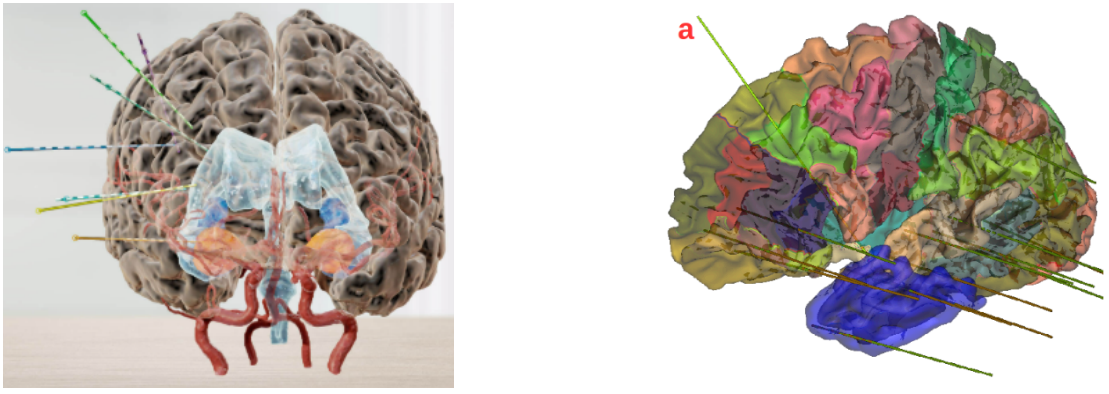


Figure 2.1 : Représentations 3D d'implantations stéréotaxique d'électrodes sEEG ciblant des structures corticales et sous-corticales

Typologie des signaux : distinguer l'activité neuronale des artéfacts

L'application d'un courant électrique au contact direct du parenchyme cérébral induit une perturbation biophysique et matérielle immédiate. Pour exploiter les enregistrements dans les études de connectivité, il est indispensable de discriminer deux catégories fondamentales de canaux :

- **Les canaux classés comme "Good"** regroupent l'ensemble des enregistrements reflétant l'activité biologique réelle du tissu cérébral :

    - **Réponses évoquées franches (CCEP) :** lorsque l'électrode enregistre une structure fonctionnellement connectée au site stimulé, le signal développe des potentiels évoqués cortico-corticaux. La morphologie typique se caractérise une déflexion appelé N1 (associé à l'activation des populations cellulaires excitatrices, avec un pic N1 entre 10 et 25 ms environ) et un complexe tardif P2-N2 (constituant une réponse tardive, formant une onde lente entre 50 et 150 ms) *[4]*. Il est important de noter que cette structure complète N1-P2-N2 n'est pas systématique : certains signaux peuvent ne présenter qu'une réponse tardive s'il n'y a pas de connexion neuronale directe entre le site stimulé et la zone d'enregistrement.

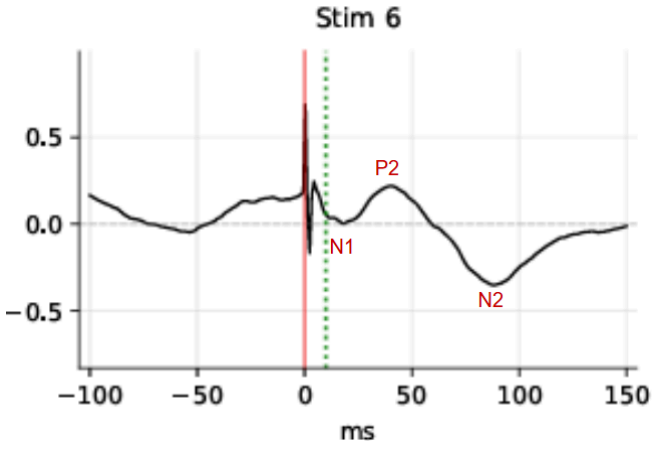


Figure 2.2 : Morphologie typique d'un potentiel évoqué cortico-cortical. *Après l'artéfact de stimulation (ligne rouge), le signal physiologique émerge.*

- **Activité physiologique de fond (réponses neutres) :** sur les canaux éloignés ou non connectés, la stimulation n'induit aucun CCEP visible. Le signal présente simplement l'activité spontanée du cortex, avec une ligne de base stable et des oscillations locales. Ces signaux doivent impérativement être conservés comme "Good" pour ne pas biaiser les analyses statistiques de connectivité.

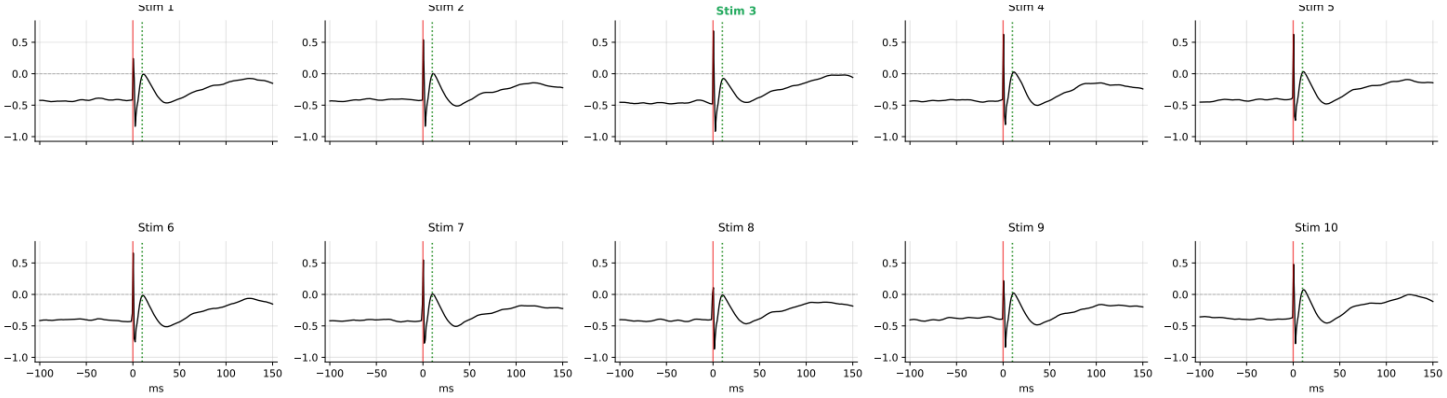


Figure 2.3 - Profil temporel d'un canal physiologique valide ("Good") sur 10 stimulations successives : *ligne de base pré-stimulation stable (-100 à 0 ms), artéfact d'impulsion électrique direct circonscrit entre 0 et 10 ms (traits rouge et vert), suivi de la dynamique neuronale caractéristique avec l'émergence des composantes N1 (pic précoce) et N2 (onde lente tardive) . (Note : L'axe des ordonnées ne représente pas l'amplitude naturelle en microvolts, les signaux ayant fait l'objet d'une normalisation par division par l'écart-type).*

- **Les signaux corrompus et artéfactés (“Bad”) : (figure 2.4)**
  Ils rassemblent les enregistrements inexploitables, dominés par des phénomènes biophysiques passifs ou des perturbations d'acquisition :

    - **Décharges capacitives :** décroissance exponentielle monotone d’amplitude massive liée à la décharge passive du tissu et de l’interface électrode-électrolyte, masquant la dynamique neuronale sous-jacente.
    - **Perturbations matérielles et bruit de référence :** sauts d’impédance, décrochages ponctuels, contamination par la référence commune ou bruit de secteur (50 Hz).

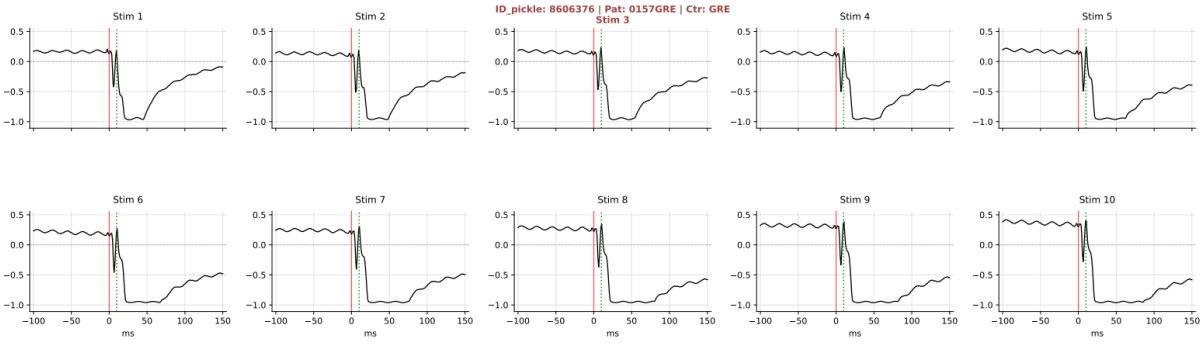


Figure 2.4 - Profil temporel d’un canal corrompu : *présence d’un bruit périodique pré-stimulation, suivie d’un effondrement brutal de tension post-impulsion et d’une saturation prolongée rendant le signal inexploitable. (Note : L'axe des ordonnées est normalisé par division par l'écart-type, de manière identique à la Figure 2.1).*

Synthèse opérationnelle

La confrontation de la Figure 2.3 et de la Figure 2.4 met en lumière le fossé existant entre une réponse biologique et un artéfact matériel critique. Cependant, la présence de nombreux cas intermédiaires *(visuel en annexe Figure A.4 et Figure A.5)* rend difficile toute tentative de filtrage par seuillage binaire. C'est précisément cette complexité qui justifie le recours à des approches d'apprentissage automatique capables d'extraire des représentations non linéaires robustes.

2. Etat de l'art scientifique et technique

Les fondations par apprentissage automatique classique

La problématique de la détection automatisée des canaux intracérébraux défectueux fait l'objet de recherches au sein de l'équipe depuis près d'une décennie. En 2018, les travaux fondateurs de Viateur Tuyisenge et al. ont démontré la viabilité des approches par apprentissage automatique (*Ensemble Machine Learning*) pour classifier les signaux sEEG *[5]*. Bien que cette méthode ait offert des performances très encourageantes, elle reposait sur un paradigme d'extraction manuelle de caractéristiques préalables (*feature engineering*). Il fallait calculer mathématiquement des descripteurs statistiques et fréquentiels sur chaque signal avant de les fournir à l'algorithme *[5]*, ce qui limitait sa flexibilité face à des artéfacts de stimulation de morphologies très hétérogènes.

Le système expert et déterministe préexistant

Avant l'introduction des approches par apprentissage automatique, l'équipe Brain Stimulation Group utilisait un algorithme déterministe formalisé par Francesco Borra. Ce système expert repose sur une conjonction logique stricte de 11 critères mathématiques et biophysiques appliqués à chaque canal i et permet de classifier chaque canal i *[1]* en un canal "good" ou "bad" (exploitable ou non) :

$$Good(i) = \left(\bigwedge_{k=1}^{11} Criterion_k(i) \right) \wedge not_stimulated(i)$$

Ces règles combinent des estimateurs statistiques, des régressions robustes et des transformations fréquentielles calculés sur le signal moyenné $S_i(t) = \frac{1}{E} \sum_{e=1}^{E} S_{i,e}(t)$ ainsi que sur les événements individuels $S_{i,e}(t)$:

- **Détection des décharges capacitives passives :** L'accumulation de charges à l'interface tissu-électrode induit une décroissance capacitive. Ce phénomène est quantifié par la pente d'une régression robuste de Theil-Sen sur la durée d'artéfact $T_{artifact,i,e}$ en fonction de l'indice ordinal de stimulation x_e :

$$\beta_i^{\text{length}} = |TheilSenSlope(x_e, T_{\text{artifact_end},i,e})|$$

Le critère impose $\beta_i^{\text{length}} \leq 0.05\ \text{ms/event}$ ou $T_{artifact,i} < 0.01s$, ainsi qu'un écart-type restreint $\text{std}_e(T_{\text{artifact},i,e}) \leq 0.01\ \text{s}$.

- **Contrôle de la forme d'onde et de la monotonicité :** Pour distinguer une réponse physiologique réelle (comportant une onde N_1) d'une simple décharge passive monotone, le signal moyenné est lissé par un filtre passe-bas Butterworth à 30 Hz ($\widetilde{S}_i(t)$). La dérivée discrète $D_i(t) = \frac{d}{dt}\widetilde{S}_i(t)$ permet de mesurer la fraction d'échantillons à pente strictement positive $frac_T^+(i)$ sur l'intervalle $T = [10ms, 100ms]$

  $mono_T(i) = \max\left(frac_T^+(i), 1 - frac_T^+(i) - frac_T^0(i)\right) + frac_T^0(i)$

  Le critère exige $mono_{T_{10-100ms}}(i) < 0.90$ pour rejeter les signaux à dynamique purement monotone.

- **Surveillance de la saturation matérielle :** Les canaux entrant en saturation lors de l'impulsion sont identifiés par le calcul de la proportion d'échantillons atteignant la tension extrême d'enregistrement $S_{\max} = \max_{i,e,t} |S_{i,e}(t)|$:

  $$frac_unsafe_{10-300}(i) = \frac{1}{E}\sum_{e=1}^{E}\left(\frac{\#\{t \in [10,300]\text{ms} : |S_{i,e}(t)| \geq S_{\max}\}}{|T_{10-300}|}\right)$$

  Le critère impose $frac_unsafe_{10-300}(i) < 0.15$ et un nombre de passages de seuil $unsafe_crossings_{10-300}(i) \leq 4$.

- **Cohérence spatiale par rapport à la référence :** La contamination globale par une électrode de référence défectueuse est mesurée via la distance relative à la médiane globale sur l'intervalle de référence ($T_{baseline} = [-0.2s, -0.01s]$) :

  $$refdist_i = \frac{|\text{median}_{e,t\in T_{\text{baseline}}} S_{i,e}(t) - \text{median}_{ch,e,t\in T_{\text{baseline}}} S_{i,e}(t)|}{|\text{median}_{ch,e,t\in T_{\text{baseline}}} S_{i,e}(t)|}$$

3. Environnement de développement et architecture de calcul

Face au volume massif des données sEEG (Plus de 13 millions de canaux de stimulations enregistrés) et à la complexité des modèles d'apprentissage profond, le dimensionnement de l'architecture de calcul a été une étape déterminante du projet. Le flux de travail a été structuré autour de deux environnements complémentaires afin d'optimiser les ressources du laboratoire.

Le serveur d'équipe : point d'ancrage et prototypage

Le serveur commun (Linux) de l'équipe Brain Stimulation Group a servi de plateforme centrale pour le développement et la gestion du code. Cet environnement interactif a permis de réaliser les phases d'ingénierie initiales :

- **Développement et versionnement :** Écriture des scripts d'extraction de données et des architectures de modèles en Python, avec un suivi de version rigoureux assuré par Git.
- **Prototypage interactif :** Utilisation d'environnements de type Jupyter pour visualiser des échantillons de signaux isolés, valider le comportement des filtres et vérifier la logique algorithmique sur des sous-ensembles restreints de la base de données.
- **Gestion modulaire des configurations :** Pour garantir la reproductibilité des expérimentations, l'ensemble des hyperparamètres (taux d'apprentissage, taille des batchs), des chemins de répertoires et des options de prétraitement a été testé sur le serveur Jupyter local.

Le cluster de l'INS : passage à l'échelle et calcul distribué

Le traitement de plus de 100 000 canaux (taille du dataset choisi pour les approches IA) et l'entraînement itératif des réseaux de neurones excédaient les capacités de mémoire (RAM) et de calcul du serveur partagé, avec un risque critique de saturation pouvant impacter les autres chercheurs. L'exécution des tâches lourdes a donc été déportée sur le

cluster de calcul haute performance (HPC) de l'INS, géré par le logiciel d'ordonnancement Slurm.

- **Isolation logicielle :** création d'environnements virtuels dédiés (via des gestionnaires comme Conda ou venv) pour encapsuler strictement les dépendances logicielles et assurer une parité totale entre le serveur de prototypage et les noeuds de calcul du cluster.
- **Soumission des expérimentations :** les lancements des pipelines de données et des scripts d'entraînement ont été exécutés soit sur le cluster de l'INS géré par Slurm pour les tâches nécessitant une puissance de calcul poussée (ex : entraînement d'une architecture CNN), soit sur le serveur d'équipe lorsque les ressources nécessaires étaient moindres (ex : visualisation des fenêtres de stimulations d'un canal).

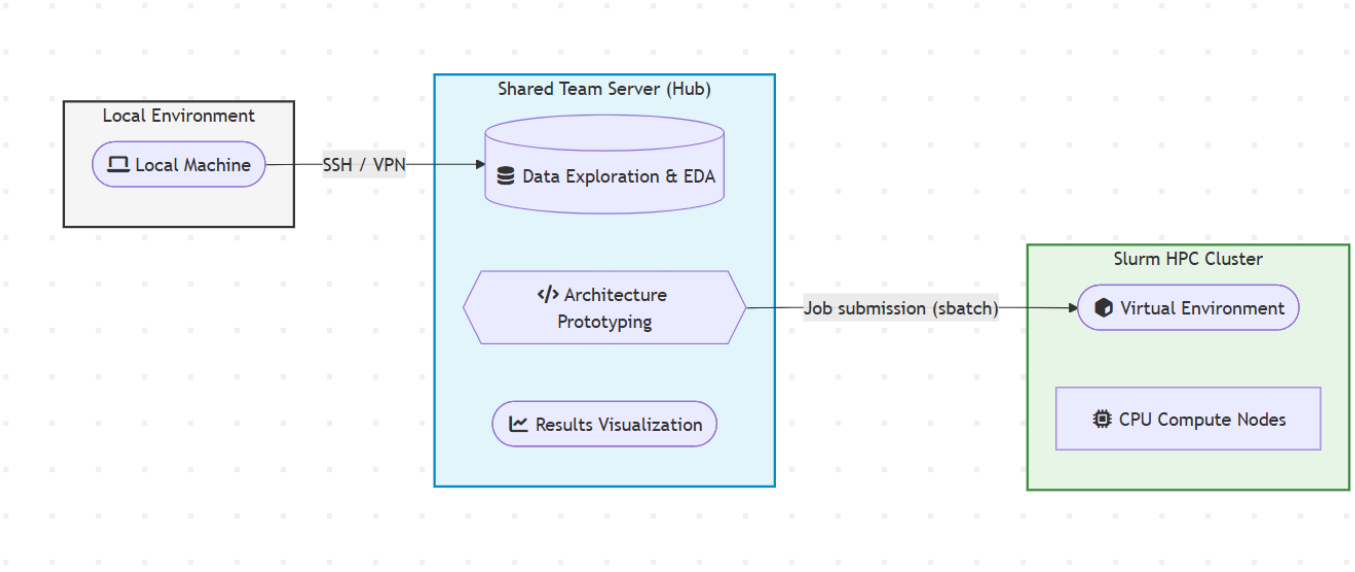


Figure 2.5 : Schéma environnement de développement

4. Ingénierie des données (Data Pipeline)

La pertinence d'un modèle d'apprentissage profond repose fondamentalement sur la qualité et la représentativité des données ingérées. Avant toute modélisation, un travail important d'exploration, de nettoyage et de structuration a été réalisé pour transformer les archives cliniques brutes en tenseurs exploitables.

Exploration, extraction, et harmonisation des signaux

Extraction événementielle : Pour chaque canal stimulé, l'algorithme parcourt les enregistrements pour isoler les fenêtres temporelles centrées sur les impulsions électriques. Chaque essai e pour un canal i est découpé en deux segments d'intérêt : une ligne de base pré-stimulation $T_{baseline} = [-0.1s, -0.01s]$ et une fenêtre d'analyse post-stimulation $T_{signal} = [0.01s, 0.15s]$.

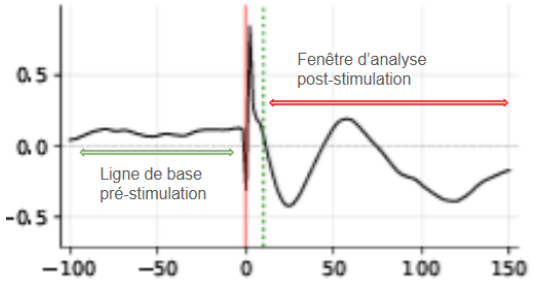


Figure 2.6 : Exemple d'une fenêtre (isolée) de stimulation d'un canal enregistré

Harmonisation des fréquences d'échantillonnage : La base de données f-tract regroupant des patients explorés dans différents centres, il existe une forte hétérogénéité des fréquences d'acquisition (allant d'environ 250 Hz à plus de 4000 Hz). Les architectures de réseaux de neurones nécessitant une dimension d'entrée statique, un module de ré-échantillonnage par interpolation a été implémenté pour aligner l'ensemble des vecteurs sur une fréquence d'échantillonnage standardisée à 1000 Hz.

Stratification par l'activité Post-Stimulation (U_i)

Lors de la constitution des ensembles d'apprentissage (train_set) et de test (test_set), un simple découpage aléatoire (random split) présentait un risque majeur de biais statistique. Les signaux sEEG étant très hétérogènes, un tirage aveugle aurait pu surreprésenter des canaux totalement plats ou concentrer tous les artéfacts massifs dans un même sous-ensemble.
Pour pallier ce problème, une stratégie d'échantillonnage stratifié a été développée en s'appuyant sur la métrique d'activité post-stimulation U_i du système déterministe. Ce descripteur, ainsi que le label dichotomique initial (*Good* ou *Bad*) issu du système déterministe, étaient déjà pré-calculés par l'algorithme de Francesco Borra *[1]* et stockés dans les métadonnées des fichiers d'archives.
Le descripteur appelé index d'activité quantifie la réactivité du canal en calculant l'écart par rapport à la médiane de la ligne de base $m_{i,e} = median_{t \in T_{baseline}} S_{i,e}(t)$. Cet écart est ensuite normalisé par l'activité globale de la ligne de base du fichier, notée BLS :

$$BLS = \sqrt{median_{ch}(median_e median_{t \in T_{baseline}}(S_{i,e}(t) - m_{i,e})^2)}$$

L'indice de stratification final est calculé de manière robuste (via des médianes) avec la formule suivante :

$$U_i = log_{10}\left(\frac{\sqrt{median_e median_{t \in T_{signal}}(S_{i,e}(t) - m_{i,e})^2}}{BLS} + 0.01\right)$$

Afin de manipuler un volume de données compatible avec des itérations rapides d'apprentissage, un sous-ensemble représentatif d'environ 100 000 canaux a été extrait de la base globale (~13 millions de canaux). Le pipeline de stratification conçu a exécuté les opérations suivantes :

1. **Segmentation en intervalles (Bins) :** La distribution globale de l'indice U_i, s'étalant sur une plage de 0 à 2, a été découpée en 20 tranches d'activité homogènes.

2. **Équilibrage dynamique et limites physiologiques :** L'objectif algorithmique initial était d'extraire une proportion stricte de 50 % de signaux Good et 50 % de Bad au sein de chaque intervalle. Toutefois, l'exploration des données a révélé une limite physiologique : les

tranches d'activité les plus élevées (fortes amplitudes) étaient structurellement dominées par des artéfacts (Bad), les canaux physiologiques viables y devenant rares.

3. **Compensation inter-bins :** Pour garantir un dataset final rigoureusement équilibré sur le plan global (soit 50 000 signaux Good et 50 000 signaux Bad), une stratégie de compensation a été implémentée. Le déficit de signaux physiologiques dans les hauts indices a été pallié par un suréchantillonnage de canaux Good dans les premiers bins (zones de faible et moyenne activité).

4. **Séparation Train / Test :** Une fois le jeu de données global constitué et équilibré, il a été scindé de manière stratifiée avec une proportion de 90 % allouée à l'entraînement (train_set) et 10 % allouée à la validation et aux tests finaux (test_set).

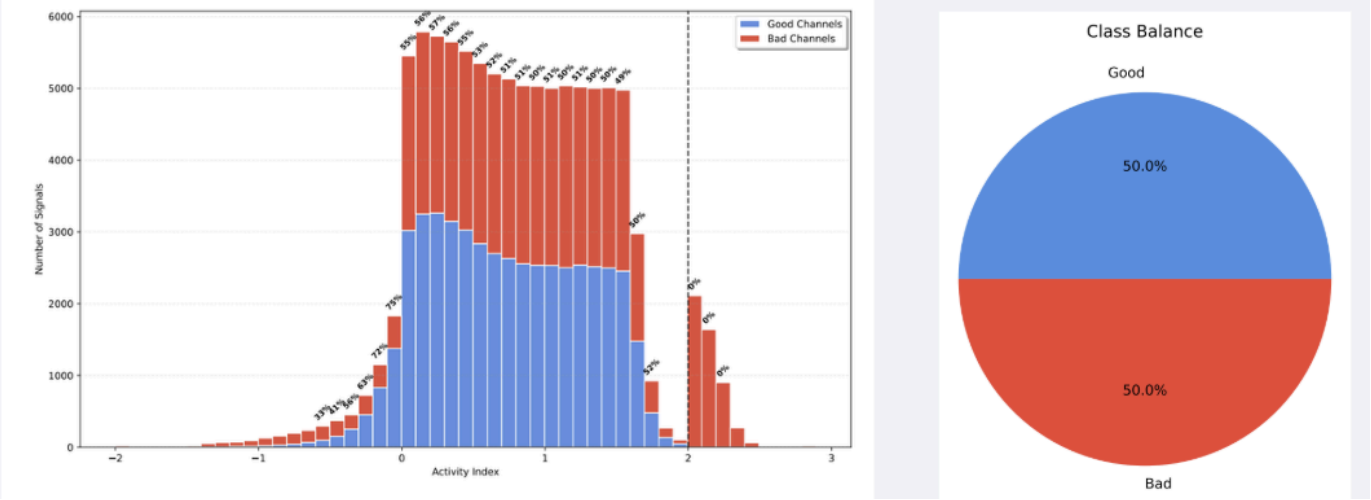


Figure 2.7 : Résumé visuel de la démarche de stratification

5. Modélisation par apprentissage automatique

Une fois le jeu de données de 100 000 canaux extrait, ré-échantillonné et stratifié, la phase de modélisation a consisté à concevoir et évaluer progressivement trois architectures d'intelligence artificielle pour séparer les signaux physiologiques (*Good*) des artéfacts (*Bad*). Le développement de celles-ci a nécessité une étroite collaboration avec l'équipe de recherche (et notamment Francesco Borra) pour concevoir des modèles adaptés à la nature spécifique des signaux sEEG. Mon rôle d'ingénieur s'est concentré sur la traduction de ces exigences méthodologiques en pipelines de Deep Learning robustes.

Référence exploratoire : l'Analyse en Composantes Principales (PCA)

Dans une démarche d'investigation rigoureuse, une approche non supervisée par PCA a été menée pour auditer la structure des données et identifier l'existence d'une séparation visible entre les canaux sains dits "Good channels" et les canaux corrompus dits "Bad channels". C'est une approche qui viendra compléter les approches de classification directe.

Cette technique a été essentielle pour établir une référence et de comprendre la topologie des données. La PCA agit ici comme un algorithme d'audit non supervisé, capable d'apprendre une distribution représentative de la diversité des good et bad channels de la base de données.

Fondements théoriques :

La PCA est une méthode de réduction de dimensionnalité qui projette les données dans un nouvel espace orthogonal en maximisant la variance *[8]*. Mathématiquement, pour un ensemble de signaux d'entrée X, l'algorithme calcule d'abord la matrice de covariance :

$$C_{ij} = \frac{1}{n}\sum_{k=1}^{n}(X_{ki} - \bar{X}_i)(X_{kj} - \bar{X}_j)$$

Afin d'obtenir une matrice de corrélation de Pearson, limitant l'influence des variations d'amplitude absolues, les variables sont préalablement divisées par leur écart-type.

La décomposition de cette matrice génère des vecteurs propres (les axes principaux de variation du signal) et des valeurs propres (la quantité d'information ou variance expliquée par chaque axe). En conservant uniquement les k vecteurs propres associés aux plus grandes valeurs propres, on compresse le signal tout en minimisant la perte d'information.
Pour évaluer la qualité de cette modélisation, on calcule l'erreur relative de reconstruction ϵ, qui représente le ratio entre l'énergie de l'erreur (la distance géométrique) et l'énergie du signal d'origine :

$$\epsilon = \frac{||x' - x||^2}{||x||^2}$$

Dans un paradigme strict de détection d'anomalies (où la PCA serait entraînée exclusivement sur des signaux physiologiques), on s'attendrait à ce qu'un artéfact inconnu génère une forte erreur de reconstruction. Cependant, notre modélisation étant appliquée conjointement sur l'ensemble du jeu de données (signaux sains et artéfactés), l'algorithme capture également la dynamique des artéfacts, dont l'erreur ne va donc pas nécessairement exploser. Par ailleurs, même pour un signal physiologique, l'erreur ne sera pas strictement nulle : elle dépend intrinsèquement du nombre de composantes principales conservées et de la structure des valeurs propres (la variance expliquée).

Implémentation appliquée :

L'implémentation de la PCA a fait l'objet d'une étude comparative sur deux échelles temporelles distinctes afin d'évaluer l'impact de la ligne de base sur les capacités de modélisation de l'algorithme.

- **Analyse sur fenêtre complète :** Une première modélisation a été appliquée sur l'intégralité du signal (250 points par événement, soit 2500 variables pour 10 stimulations). La matrice de covariance massive de 2500×2500 a permis d'extraire les dynamiques globales, incluant la variabilité du bruit de fond pré-stimulation.

- **Analyse ciblée post-stimulation :** Pour affiner la représentation, une seconde approche a exclu la ligne de base afin de se concentrer exclusivement sur la réponse physiologique induite. Les fenêtres ont été réduites à 140 points d'intérêt post-stimulation, générant un vecteur d'entrée compressé à 1400 variables, et une matrice de covariance de 1400×1400.

Sur ces deux approches, l'extraction par Décomposition en Valeurs Singulières (SVD) a démontré qu'une dizaine de composantes principales suffisait à capturer près de 89,39 % de la variance physique des signaux. Cette comparaison méthodologique a permis de comprendre la structure de l'espace latent et de valider que la dynamique neurophysiologique pouvait être fortement compressée, pavant la voie aux modèles d'apprentissage profond.

Classification supervisée : réseaux de neurones convolutifs (CNN)

Pour automatiser la classification binaire (Good / Bad), l'approche s'est tournée vers les réseaux de neurones convolutifs. Bien que traditionnellement utilisés pour l'image, les CNN se révèlent extrêmement performants sur les séries temporelles grâce à leur capacité à extraire des motifs morphologiques locaux (pics physiologiques ou décharges capacitives).

Fondements théoriques et Entropie Croisée Binaire (BCE) :

L'apprentissage d'un réseau de neurones nécessite une fonction de perte (ou fonction de coût) pour quantifier l'erreur de ses prédictions. Pour un problème de classification binaire, la norme mathématique est la Binary Cross-Entropy (BCE) *[7]*.
La BCE mesure la divergence entre la probabilité prédite par le modèle $\hat{y}_i \in [0, 1]$ et la vérité terrain $y_i \in \{0, 1\}$ de l'expert clinique. Son équation s'écrit :

$$BCE = -\frac{1}{N}\sum_{i=1}^{N}\left[y_i \log(\hat{y}_i) + (1 - y_i)\log(1 - \hat{y}_i)\right]$$

Si le signal est sain ($y_i = 0$), la formule annule le premier terme et pénalise fortement le réseau si $\hat{y}_i$ s'approche de 1 (via le logarithme de $1 - \hat{y}_i$).
Dans la pratique, si le réseau est trop confiant et se trompe (ex: $\hat{y}_i \approx 0$ pour $y_i = 1$), le logarithme de 0 tend vers l'infini, ce qui fait crasher l'algorithme. L'implémentation industrielle contourne ce problème d'instabilité en combinant mathématiquement la fonction d'activation logistique (Sigmoïde) et la BCE au sein d'une seule et même opération optimisée.

Implémentation appliquée sous PyTorch :

Le réseau a été conçu (SEEG2DCNN) pour ingérer des tenseurs 4D de forme (32, 2, 10, 250). La première dimension (32) correspond à la taille du lot (*batch size*), un paramètre exclusif à la phase d'apprentissage et non utilisé lors des tests. La deuxième dimension (2) correspond aux canaux d'entrée : le premier contient l'amplitude brute du signal, tandis que le second intègre un vecteur temporel artificiel (progressant linéairement de -1.0 à +1.5). Cet ajout agit comme une caractéristique (*feature*) temporelle explicite concaténée au signal pour pallier l'aveuglement des convolutions. Enfin, les dimensions 10 et 250 correspondent respectivement aux 10 événements de stimulation successifs extraits sur 250 points temporels (de -100 ms à +150 ms).

- **Conv1 et Pooling inter-essais :** Une première couche de 16 filtres avec un noyau asymétrique de (1, 10) parcourt le temps. Elle est immédiatement suivie d'une opération MaxPool2d avec un noyau très spécifique de (10, 1). Ce choix d'ingénierie écrase la dimension des 10 stimulations pour ne conserver que l'activation maximale inter-essais à chaque pas de temps, fusionnant ainsi l'information redondante dès le début du réseau.

- **Conv2 & Conv3 :** Le tenseur traverse ensuite deux couches successives (32 puis 64 filtres, noyaux de (1, 10), strides de (1, 5)) couplées à des activations ReLU pour extraire les caractéristiques de haut niveau.

Après aplatissement (Flatten), le vecteur de 512 caractéristiques alimente un perceptron multicouche (Linear(512, 64) puis Linear(64, 1)). L'optimisation a été pilotée par l'algorithme Adam (taux d'apprentissage de 0,001). La stabilité numérique de l'apprentissage a été garantie par l'utilisation de la fonction BCEWithLogitsLoss de PyTorch *[9]*, fusionnant la couche Sigmoïde et l'entropie croisée pour éviter les instabilités du calcul logarithmique.

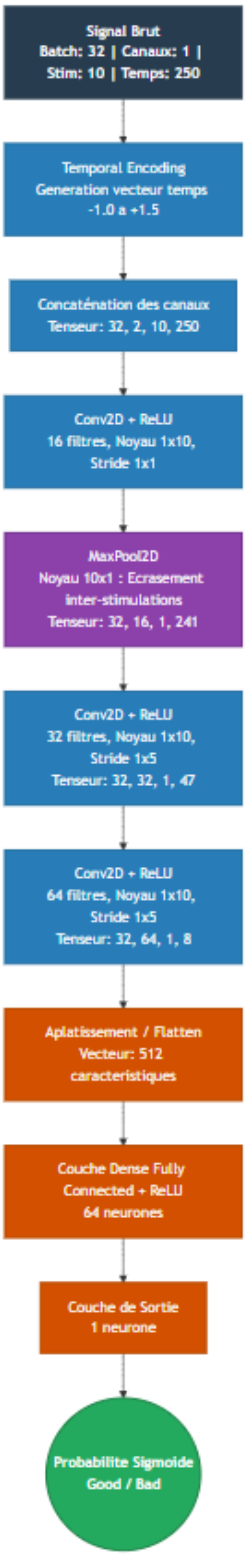


Figure 2.8 : Résumé de l'architecture du CNN retenu

Approche avancée : autoencodeurs multi-tâches (AE)

Classiquement, un autoencodeur est une architecture de réseau de neurones artificiels conçue pour apprendre une représentation compressée d'un jeu de données de manière non supervisée *[7][11]*. Le modèle se divise en deux parties symétriques : un encodeur qui projette les données de grande dimension vers un espace réduit appelé « espace latent » (ou goulot d'étranglement), et un décodeur qui tente de reconstruire le signal d'origine à partir de ce vecteur compressé. En forçant l'information à passer par ce goulot d'étranglement, le réseau ne peut pas simplement mémoriser les données ; il est contraint d'en extraire les caractéristiques mathématiques et morphologiques les plus fondamentales pour minimiser son erreur de reconstruction.

Cependant, afin de dépasser la simple réduction de dimension et de capturer simultanément la géométrie continue des signaux sEEG et la décision médicale, l'architecture a évolué vers un Autoencodeur multi-tâches hybride.

Fondements théoriques et apprentissage multi-objectifs (HybridLoss) :

Contrairement à un autoencodeur standard qui ne minimise que la reconstruction, ce modèle intègre une fonction de perte composite (HybridLoss) spécifiquement paramétrée pour forcer la structuration de l'espace latent, pondérée par un hyperparamètre $\alpha = 0,1$. La perte globale s'articule autour de trois composantes :

1. **L1 (Reconstruction invariante à l'échelle) :** L'erreur quadratique de reconstruction est divisée par une constante dynamique W (la moyenne de l'énergie des signaux originaux du lot) pour éviter que les ondes de très forte amplitude ne dominent l'apprentissage abstrait des formes.

2. **L2 (Classification) :** L'entropie croisée binaire (BCEWithLogitsLoss) est divisée par $\ln(2)$ pour normaliser mathématiquement le coût logistique de la classification.

3. **L3 (Régression) :** L'erreur quadratique moyenne standard (MSE) est appliquée pour contraindre la prédiction de l'indice d'activité physiologique (U_i).

L'équation globale d'optimisation implémentée dans les scripts s'écrit donc :

$$\mathcal{L}_{total} = \mathcal{L}_1 + \alpha\mathcal{L}_2 + \alpha\mathcal{L}_3$$

Implémentation appliquée sous PyTorch :

La structure de base du réseau repose sur l'ingestion de fenêtres temporelles individuelles de 250 points, pré-traitées par un centrage sur la ligne de base pré-stimulation (-100 ms à 0 ms) et par une division sur l'écart-type global du jeu de données.

Pour garantir un apprentissage robuste sans sur-complexifier le modèle, l'encodeur comprime l'information via une cascade stricte de couches denses associées à la fonction d'activation ReLU (250 $\rightarrow$ 128 $\rightarrow$ 64 $\rightarrow$ 4 dimensions). Ce goulot d'étranglement de 4 dimensions est découpé de manière chirurgicale :

- Les deux premières dimensions (latent[:, :2]) encapsulent la topologie géométrique 2D du signal.

- La troisième dimension (latent[:, 2:3]) extrait le logit pour la discrimination probabiliste (Good/Bad).

- La quatrième dimension (latent[:, 3:4]) force le réseau à régresser l'indice d'activité.

Le tenseur compressé traverse ensuite un décodeur symétrique (4 $\rightarrow$ 64 $\rightarrow$ 128 $\rightarrow$ 250) activé par des ReLU, afin de reconstruire la forme de l'onde originelle en sortie.

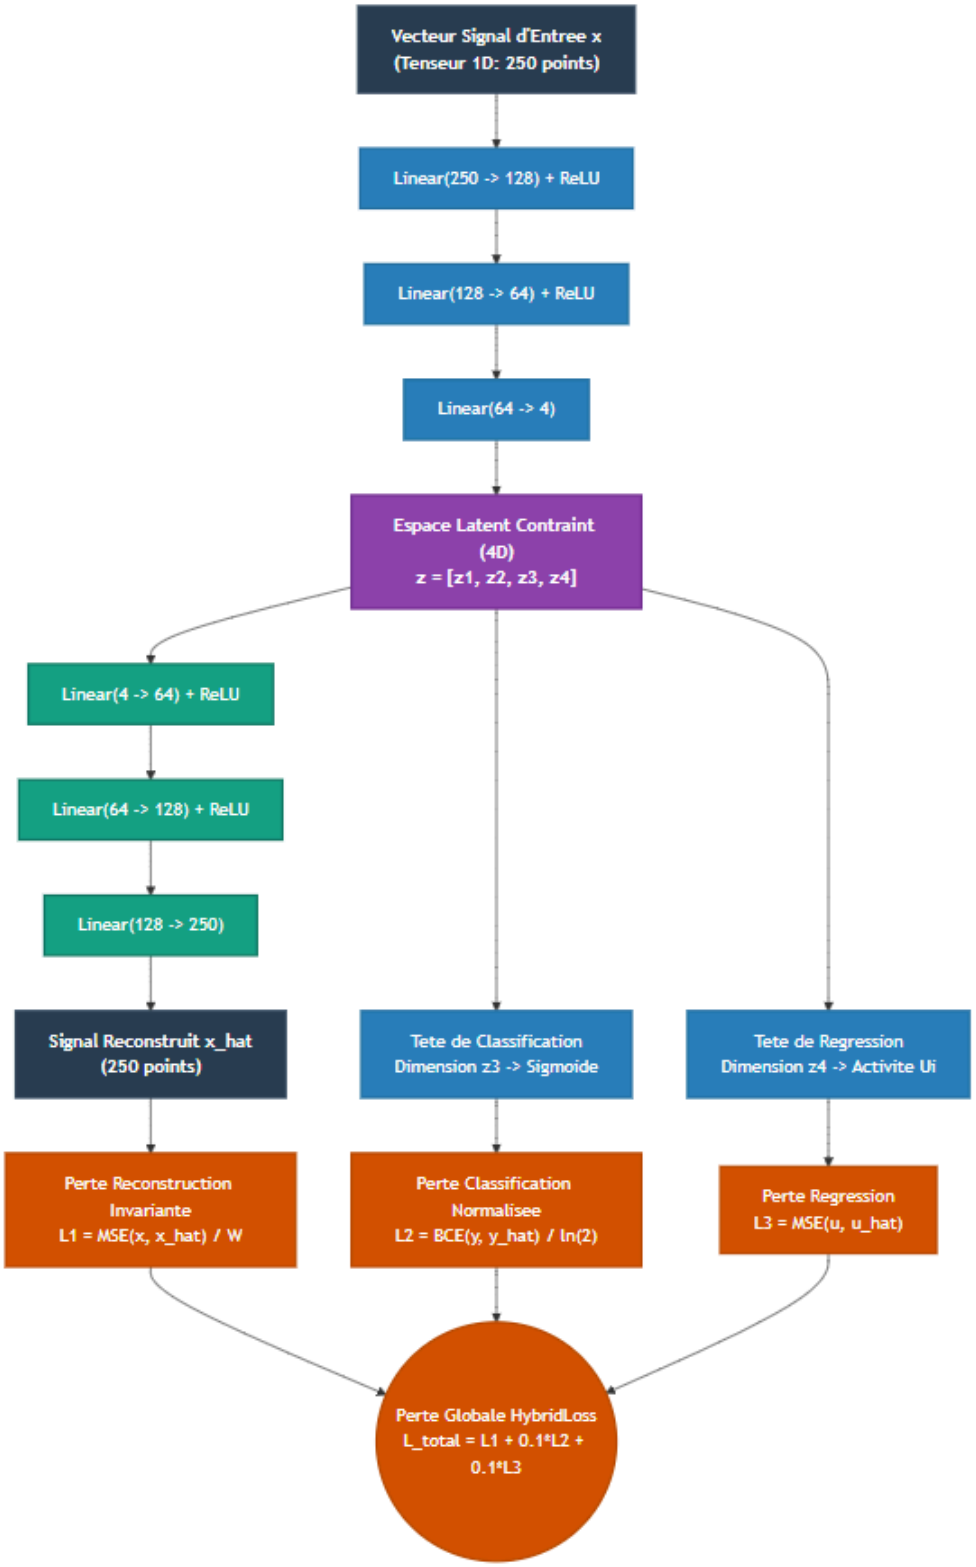


Figure 2.9 : Résumé de l'architecture globale de l'un des Autoencodeurs développé

Chapitre 3 : Résultats, Analyse Comparative et Retombées scientifiques

1. Méthodologie d'évaluation et Vérité Terrain

Avant d'analyser les performances des différentes architectures de modélisation, il est impératif de définir un cadre d'évaluation rigoureux. La pertinence d'une métrique d'intelligence artificielle reposant intégralement sur la qualité de ses étiquettes de test, une refonte de la base d'évaluation a été opérée.

Constitution d'un dataset de vérité terrain

Le jeu de données global de 100 000 canaux ayant été étiqueté par l'ancien système déterministe, il comportait un bruit de labellisation inévitable (faux positifs et faux négatifs liés à la rigidité des 11 critères mathématiques). Évaluer un réseau de neurones sur des données potentiellement faussées reviendrait à lui reprocher de ne pas reproduire les erreurs de l'ancien système.

Pour briser ce biais, un jeu de test vérité terrain a été isolé puis soumis à une révision manuelle stricte. En collaboration avec l'expertise neurophysiologique de l'équipe de recherche (M. Francesco Borra), chaque canal de ce sous-ensemble a été inspecté visuellement pour confirmer formellement sa viabilité physiologique (« Good ») ou sa corruption (« Bad »).

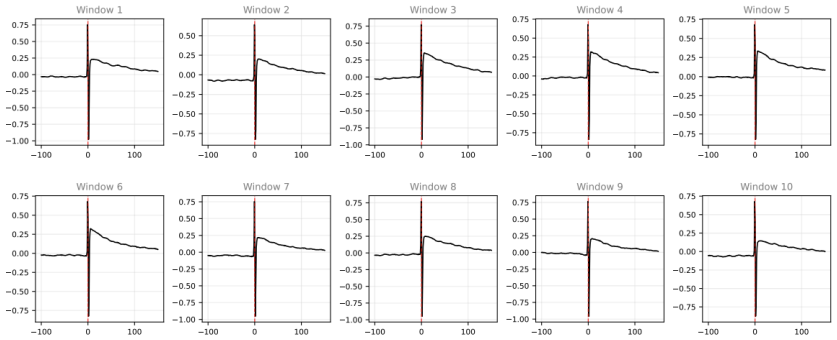


Figure 3.1 : Exemple d'inspection visuelle d'un canal patient pour la validation de la Vérité Terrain.

Topologie des données et séparation Train/Test

La répartition finale des données stratifiées s'établit ainsi :

- **Ensemble d'entraînement (Train Set) :** ~90 000 canaux, utilisés pour optimiser les poids des réseaux de neurones (rétropropagation) et ajuster les hyperparamètres.
- **Ensemble de test (Test Set) :** ~10 000 canaux utilisés uniquement pour l'évaluation finale et comparative des algorithmes. Dont 500 vérifiés manuellement.

Choix des métriques de classification

Afin de confronter les architectures sur des bases purement objectives, trois indicateurs statistiques standards ont été retenus pour évaluer les prédictions sur la vérité terrain :

- **Dynamique d'apprentissage :** Analyse des courbes de perte (*Losses*) en entraînement et en validation pour s'assurer de la bonne convergence des modèles et exclure tout phénomène de surapprentissage (*overfitting*).
- **La précision (l'accuracy)**
- **Le F1-score :** pertinent pour s'assurer que le modèle ne privilégie pas abusivement une classe notamment dans le domaine médical.
- **L'histogramme des probabilités**
- **Matrices de confusion**
- **Evaluation de l'espace latent (PCA et Autoencodeurs) :** Calcul de la variance expliquée pour évaluer la compression de l'information (PCA).
- **Nuages de points :** inspection visuelle pour vérifier la séparabilité mathématique des classes.
- **Audit clinique des prédictions :** Vérification visuelle sur des échantillons du jeu de test des Vrais Positifs (TP), Vrais Négatifs (TN), Faux Positifs (FP) et Faux Négatifs (FN) afin de comprendre concrètement sur quels types de signaux physiologiques complexes ou artéfacts subtils les algorithmes se trompent.

2. Limites de l’approche linéaire de référence (PCA)

L'Analyse en Composantes Principales a été déployée en première intention comme *baseline* d'audit non supervisé. Les signaux ont été stratifiés par tranches d'activité (bins) afin d'évaluer la topologie des données sur différentes dynamiques d'amplitude. Si la Décomposition en Valeurs Singulières (SVD) confirme une forte redondance de l'information, une dizaine de composantes suffisent à capturer près de 90 % de la variance physique , la projection dans cet espace latent révèle les limites intrinsèques des approches linéaires face à la complexité de la sEEG.

Un espace latent non séparable

Pour éprouver les véritables capacités de séparation de l'algorithme, l'audit visuel s'est spécifiquement focalisé sur la tranche d'activité (*bin*) la plus critique : celle présentant le chevauchement le plus dense et le plus équilibré entre les canaux « Good » et « Bad » *(Figure 3.2 ci-dessous)*. Ce choix permet d'exclure les cas triviaux (canaux parfaitement plats ou saturations extrêmes) pour se concentrer sur la zone où le tri algorithmique est réellement indispensable. C’est-à-dire la zone de canaux ayant un index d’activité entre 0.3 et 1.1. L'analyse des nuages de points de cet intervalle projetés sur les composantes principales majeures met en évidence une intrication massive des classes. Bien que la PCA parvienne à repousser en périphérie quelques artéfacts atypiques, l'immense majorité des signaux corrompus se superpose intégralement à la distribution des signaux physiologiques sains. Une projection orthogonale linéaire échoue donc à tracer une frontière de décision claire pour démêler la signature morphologique d'un CCEP de celle d'un artéfact électrique.

L’impasse de l’erreur de reconstruction

L'étude de la distribution de l'erreur relative de reconstruction (ϵ) confirme cette limitation géométrique. L'hypothèse d'une détection d'anomalies par apprentissage non supervisé suggérait qu'un artéfact inattendu générerait une erreur de reconstruction plus élevée qu'un signal physiologique. Toutefois, ce principe s'applique principalement lorsqu'une PCA est

entraînée exclusivement sur des signaux sains. Dans notre cas d'un apprentissage conjoint sur toutes les données, l'algorithme capture également une part de la dynamique des artéfacts. Par conséquent, les histogrammes d'erreur démontrent que la PCA agit ici comme un classifieur de faible qualité : de nombreux canaux artéfactés sont reconstruits avec un niveau de précision très proche des signaux sains. Fixer un seuil de discrimination binaire sur cette erreur de reconstruction entraînerait inévitablement un taux inacceptable de faux positifs (rejet de signaux sains).

Cette phase d'audit linéaire confirme formellement que la discrimination des artéfacts de stimulation sEEG constitue un problème hautement non linéaire, justifiant l'exploration d'architectures d'apprentissage profond (bien que l'utilisation d'autres approches linéaires avancées eût pu théoriquement être envisagée).

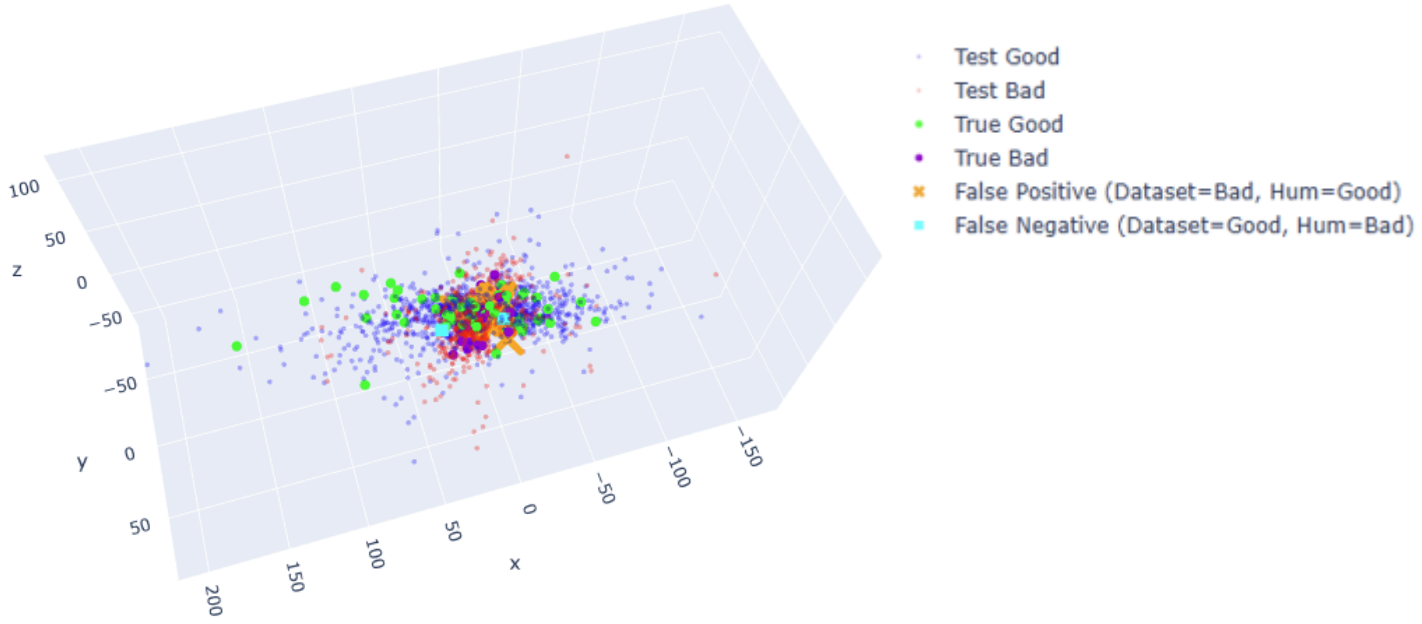


Figure 3.2 : Séparation de la zone d'activité d'index la plus confuse

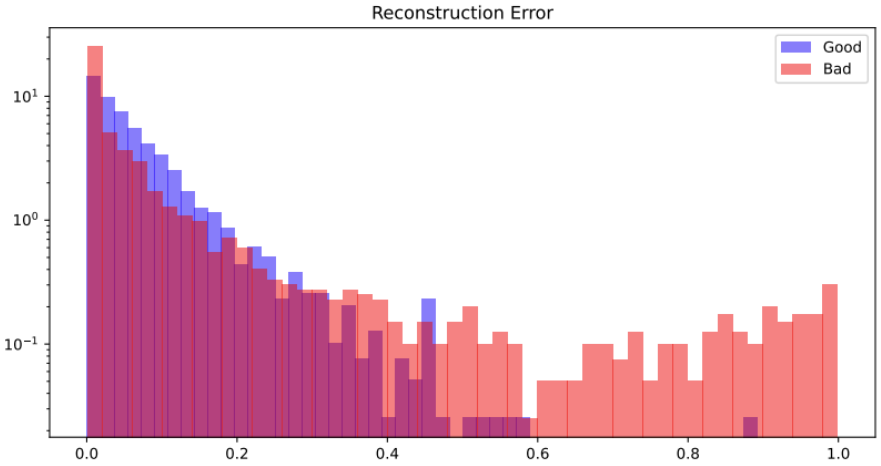


Figure 3.3 : Histogramme de la reconstruction d'erreur : *Ordonnées = nombre de canaux en échelle logarithmique / Abscisses = erreur de reconstruction entre 0 et 1.*

3. La supériorité de la classification supervisée (CNN)

Dynamique d'apprentissage et prévention du surajustement

L'entraînement de l'architecture convolutive a fait l'objet d'un suivi rigoureux via les courbes de perte (*BCE Loss*) afin de garantir la stabilité de l'apprentissage. Les métriques indiquent une convergence saine du modèle jusqu'à l'époque 21. Au-delà de cette 21ème itération, la perte d'entraînement continue de chuter de manière logarithmique tandis que la perte de validation remonte brusquement, signant le début d'un phénomène de surapprentissage (*overfitting*). Le mécanisme d'arrêt précoce (*Early Stopping*) a joué son rôle en sauvegardant l'état du modèle à l'époque 21, qui constitue le point d'arrêt optimal pour garantir la capacité de généralisation des caractéristiques extraites.

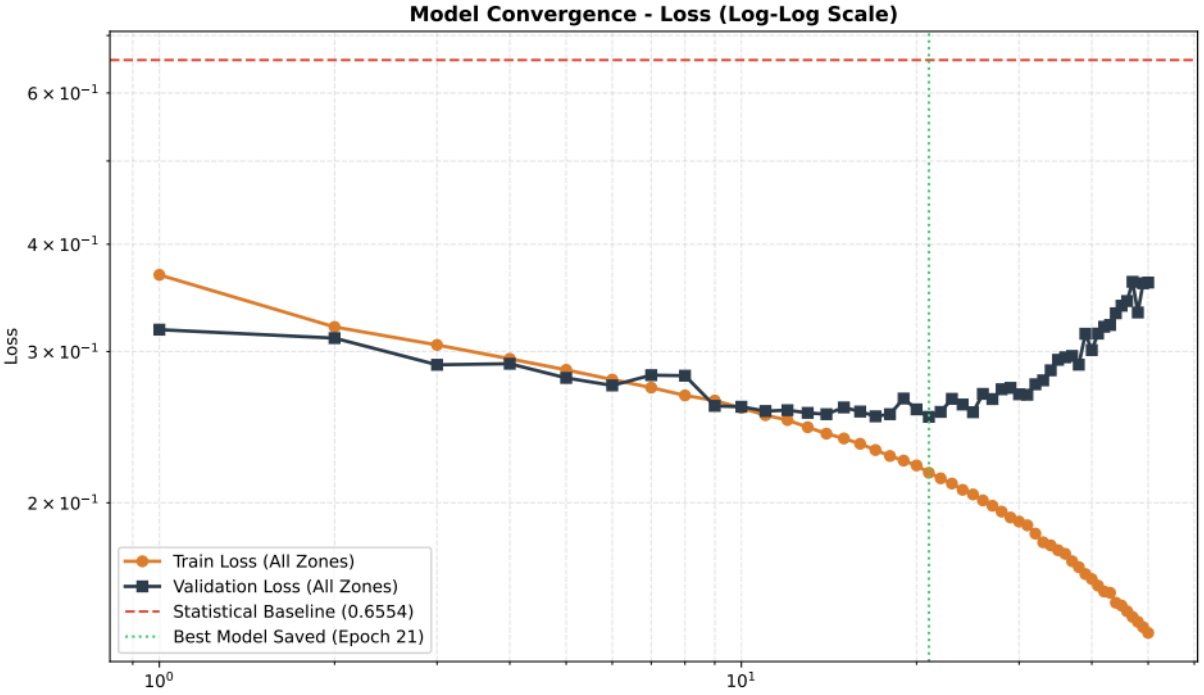


Figure 3.4 : Courbe de Loss de l'architecture de CNN retenue

Performances quantitatives globales et confiance prédictive

Déployé sur l'ensemble de validation complet représentant 9902 signaux sEEG, le réseau CNN 2D affiche une exactitude de 89.24 %. La matrice de confusion globale démontre une grande sensibilité aux canaux physiologiques, avec 94.7 % des signaux sains correctement préservés, tout en rejetant efficacement 83.8 % des signaux corrompus. L'étude de l'histogramme des probabilités de sortie du réseau confirme la robustesse de l'espace de décision : dès les premières époques, le modèle s'affranchit des zones d'incertitude (autour du seuil de classification de 0.5) pour polariser massivement ses prédictions vers les bornes 0.0 (Good) et 1.0 (Bad), témoignant d'une forte confiance algorithmique. L'analyse zonale confirme par ailleurs que les performances s'élèvent jusqu'à 99.80 % de précision sur les signaux présentant les plus hauts indices d'activité.

Validation neurophysiologique sur la Vérité Terrain

La valeur clinique du modèle a été auditée sur l'échantillon indépendant de 500 canaux constituant la Vérité Terrain. Face au jugement d'un expert humain, le modèle CNN 2D a correctement classifié 245 signaux physiologiques et 178 artéfacts majeurs. Le réseau génère 49 faux positifs (signaux étiquetés "Bad" par l'humain mais "Good" par l'IA) et seulement 28 faux négatifs. Ce faible taux de faux négatifs est une caractéristique qui valide neurophysiologiquement le modèle pour un outil de traitement biomédical, garantissant qu'un minimum de canaux inexploitables ne vienne polluer les analyses de connectivité en aval. Pour évaluer objectivement l'apport de ce réseau de neurones face au système déterministe précédent, il convient de confronter leurs scores de concordance respectifs vis-à-vis de l'expert humain. L'étiquetage d'origine, généré par l'algorithme déterministe, affiche une concordance de 81.60 % avec la Vérité Terrain. Le modèle CNN 2D atteint une concordance de 84.60 % avec cette même Vérité Terrain, soit une différence apparente de +3.00 % en faveur du CNN. Afin de vérifier si cet écart est statistiquement significatif, un test de rapport de vraisemblance binomial a été appliqué sur cet échantillon de 500 éléments. La p-value obtenue s'établit autour de $p \approx 0.10$. Bien que ce résultat démontre une tendance favorable pour le réseau de neurones, il souligne également la nécessité d'étendre la Vérité Terrain à un échantillon plus vaste pour franchir le seuil de significativité statistique strict ($p < 0.05$).

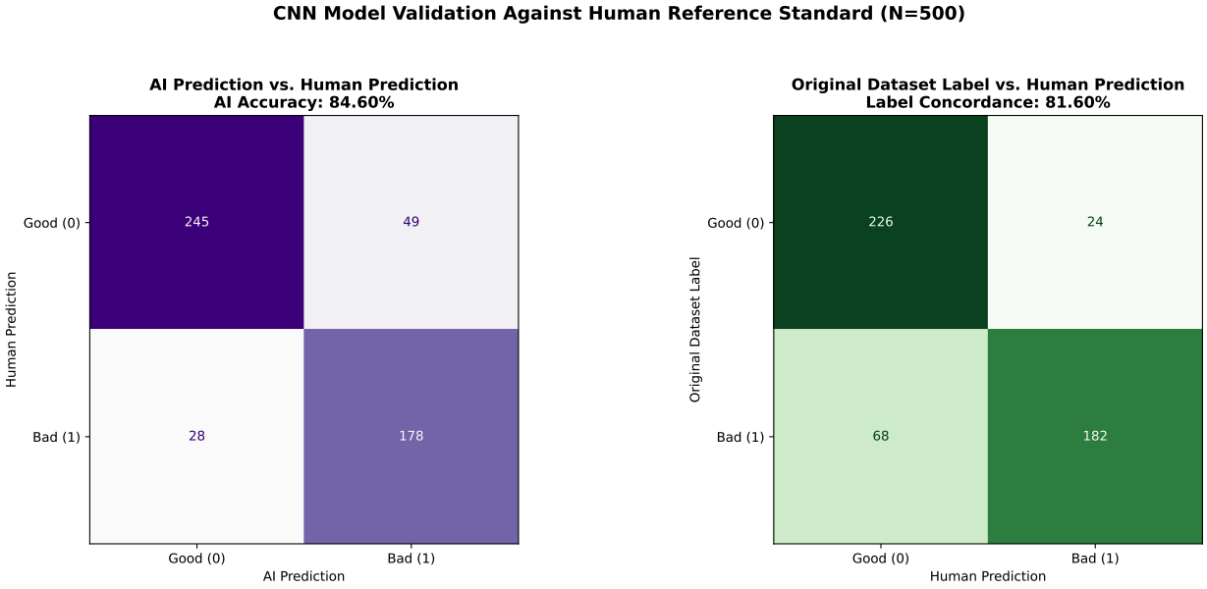


Figure 3.5 : Matrices de confusion symbolisant la différence entre la classification CNN et la classification déterministes déjà existante

4. Apports de l'Autoencodeur : Modélisation générative et Séparabilité

Si le CNN 2D a été optimisé pour maximiser la performance prédictive brute, le développement de l'Autoencodeur entièrement connecté (FCAE) répondait à une démarche exploratoire double :

1. **Évaluer la capacité générative d'un modèle** sur des signaux sEEG (reconstruire de toutes pièces une onde physiologique ou un artéfact).
2. **Forcer l'apprentissage d'une représentation optimale**, en vérifiant si la contrainte de reconstruction permettait de séparer naturellement les données de manière plus nette qu'une approche supervisée classique ou qu'une PCA.

Validation de la capacité générative

La capacité du réseau à comprendre et à générer la physique des signaux est validée par les fenêtres de reconstruction. Confronté à un canal physiologique sain, le décodeur (agissant comme générateur) parvient à redessiner la dynamique temporelle caractéristique en lissant le bruit de fond. Face à un canal corrompu, il reproduit avec précision la chute brutale de tension typique d'une décharge capacitive. L'algorithme prouve ainsi qu'il n'a pas simplement mémorisé des étiquettes, mais qu'il est capable de généraliser une représentation mathématique robuste de la dynamique du signal.

Une séparabilité accrue de l'espace latent

L'accomplissement majeur de cette architecture hybride réside dans la topologie de son espace latent. En forçant la compression de l'information vers un vecteur à 4 dimensions, le réseau a dû organiser les signaux pour minimiser son erreur de reconstruction (L1) et de classification (L2). La projection 3D de cet espace latent démontre une séparation géométrique claire et nette, avec une bifurcation évidente entre les signaux physiologiques (en bas, en vert/bleu) et les artéfacts (repoussés en haut, en rouge). L'Autoencodeur met en évidence ce que la PCA avait balbutié à faire : il a distordu l'espace pour rendre le problème linéairement séparable.

Une polarisation extrême des probabilités

L'histogramme de distribution des probabilités indique une absence quasi totale d'incertitude dans les prédictions. Au lieu d'hésiter autour d'un seuil de 0.5, le modèle rejette massivement ses prédictions vers les extrêmes absolus (0.0 pour une certitude physiologique, 1.0 pour une certitude d'artéfact). Cette robustesse confirme que l'ajout d'une tâche de reconstruction (génération) améliore significativement la qualité de la classification.

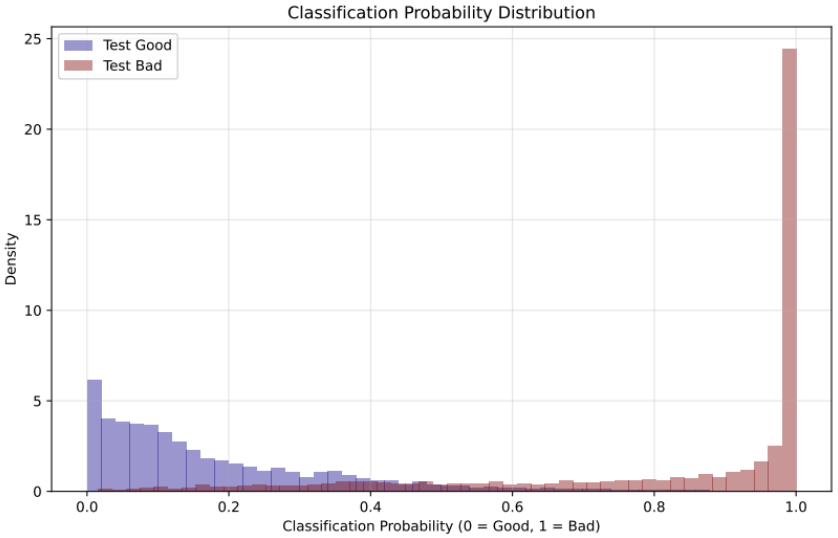


Figure 3.6 : Histogramme de la distribution des probabilités

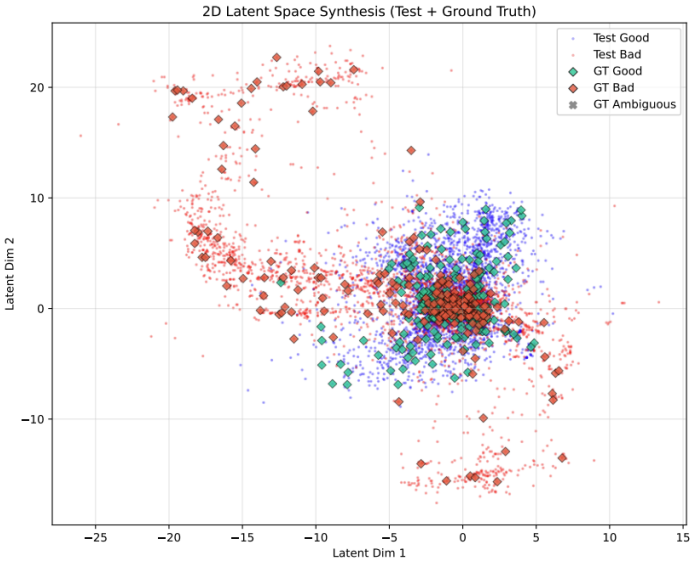


Figure 3.7 : Séparation en 2D de l'autoencodeur

Performances de classification sur la Vérité terrain

Pour évaluer rigoureusement la qualité de classification de l'Autoencodeur, celui-ci a été soumis au même ensemble de Vérité Terrain (500 canaux) que le réseau convolutif. Sur cet échantillon, le modèle hybride a correctement classifié 243 signaux physiologiques et 177 artéfacts majeurs. Il génère 51 faux positifs et 29 faux négatifs. L'exactitude (*accuracy*) de l'Autoencodeur s'établit ainsi à 84,00 % de concordance avec l'expert humain.

Bien que ce score démontre des capacités prédictives très solides découlant de la structuration de l'espace latent, il reste légèrement inférieur à la concordance atteinte par le CNN 2D (84,60 %). Cette légère baisse de performance brute justifie le choix de privilégier l'architecture purement convolutive pour le pipeline de classification final, tout en conservant l'Autoencodeur comme un puissant outil d'exploration générative.

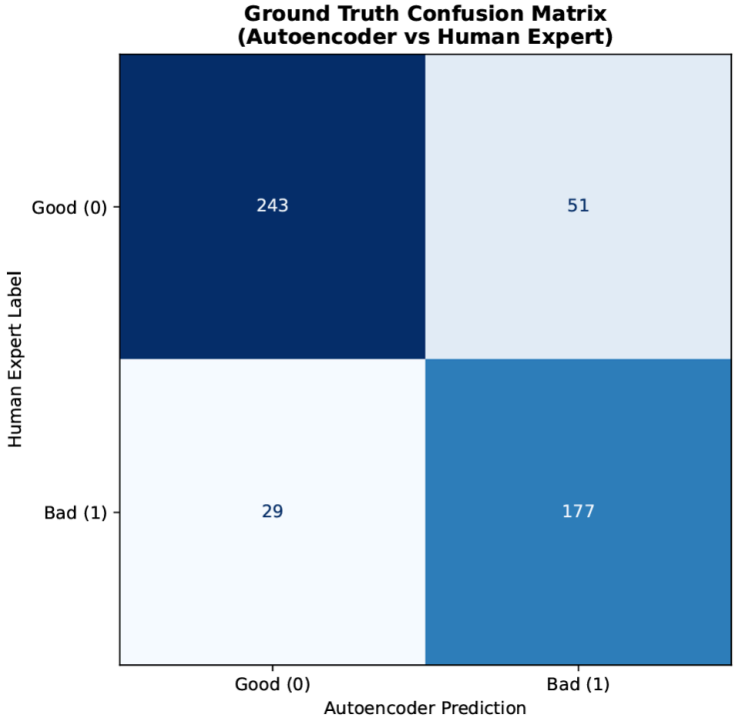


Figure 3.8 : Matrice de confusion de l'Autoencoder sur l'échantillon de Vérité Terrain

5. Bilan comparatif

L'exploration successive de ces trois architectures a permis d'automatiser et fiabiliser le tri des signaux sEEG à une échelle massive. Chaque modèle a joué un rôle stratégique dans la compréhension et la résolution de ce verrou technologique.

Synthèse des approches évaluées

La référence linéaire (PCA) : Elle a agi comme un outil d'audit fondamental. En démontrant l'incapacité d'une projection orthogonale à séparer les signaux sains des artéfacts, elle a justifié le basculement nécessaire vers des approches non linéaires.
L'Autoencodeur multi-tâches (AE) : En prouvant sa capacité générative à reconstruire la physique du signal et en séparant bien mieux les classes dans son espace latent, il a démontré que l'intelligence artificielle ne se contentait pas de mémoriser des statistiques, mais était capable de mémoriser l'allure neurophysiologique de l'onde.
Le Réseau Convolutif (CNN 2D) : Il s'est imposé comme le moteur prédictif le plus performant. Optimisé pour extraire des motifs morphologiques locaux à travers les essais, il a délivré les meilleures métriques de classification brute et la plus forte concordance avec l'expert humain (84,60 %, surpassant les 81,60 % du système historique).

Préconisations technologiques et perspectives de déploiement

Au regard des performances obtenues, l'architecture CNN 2D se dégage comme le candidat idéal pour intégrer un futur pipeline de l'équipe. Ce serait un bon compromis qui offrirait vitesse d'inférence et robustesse face à la grande variabilité inter-patients.

Bien que le déploiement définitif de ce modèle ne soit pas encore effectif à l'issue de ce stage, ces travaux établissent une solide preuve de concept (PoC). Ils démontrent que le remplacement du système expert historique par l'intelligence artificielle est non seulement réalisable, mais qu'il apportera des bénéfices comme la diminution de faux positifs.

Chapitre 4 : Gestion de Projet

La conduite d'un projet de recherche en deep learning appliqué à la neurophysiologie diffère structurellement des méthodologies de développement logiciel classiques (cycle en V). L'exploration algorithmique sur des données biomédicales massives impose une gestion itérative, s'apparentant aux principes de la méthode Agile. L'incertitude inhérente à la recherche de pointe, notamment pour évaluer la pertinence d'une architecture CNN face à un Autoencodeur, a nécessité un haut degré d'autonomie. Ce pilotage s'est appuyé sur un système d'échéances que je me suis auto-imposé permettant de borner les phases d'exploration et d'éviter l'enlisement sur des pistes infructueuses.

1. Organisation du projet et parties prenantes

Au sein de l'équipe, la gouvernance s'est articulée autour d'un pilotage par objectifs plutôt que par un micro-management chronologique. La validation stratégique de la direction clinique était assurée par le chef d'équipe de manière asynchrone, garantissant le bon alignement des modèles d'intelligence artificielle développés avec les besoins réels du laboratoire.

Sur le plan opérationnel, l'ingénierie s'est appuyée sur une boucle d'amélioration continue grâce à un mentorat technique rapproché. Le travail de recherche mené conjointement avec un post-doc de l'équipe (Francesco) a permis d'instaurer un suivi quotidien. Ce retour d'expérience journalier a sécurisé la compréhension fine de la physiologie des signaux sEEG et son expérience en machine learning ont permis de m’aiguiller vers les bonnes réflexions et de m’empêcher de continuer vers des impasses.

Les jalons majeurs de ce projet ont été matérialisés par deux restitutions formelles devant l'ensemble des membres du laboratoire, servant de revues de sprint pour confronter les avancées à l'expertise collective.

Afin de formaliser cette dynamique d'équipe, une matrice RACI (Réalisateur, Approbateur, Consulté, Informé) a été établie pour cartographier les niveaux de responsabilité de chaque partie prenante.

Phase du Projet	Célian DI GIOVANNI (Ingénieur stagiaire)	Olivier David (Directeur de recherche)	Francesco Borra (Post-Doc)	Maciej Jedynak (Post-Doc)	Sofia Avalos Alais (Doctorante)	Anthony Boyer (Ingénieur)
Définition des objectfis cliniques	C	A/R	C	I	I	I
Ingénierie des données et stratification	A/R	I	A	I	I	I
Développement des modèles IA (CNN, AE)	A/R	I	A/C	I	I	I
Validation avec la vérité terrain	R	C	A/R	C	C	C
Analyse des résultats et impacts	R	A	A/R	I	I	I

R - Réalisateur : Personne qui développe concrètement la solution technique ou algorithmique.
A - Approbateur : C'est la personne qui valide le travail technique.
C - Consulté : Expert sollicité pour son apport métier, clinique ou méthodologique.
I - Informé : Parties prenantes tenues au courant de l'avancement global ou de la clôture d'un jalon.

Figure 4.1 : Matrice RACI - Projets IA - Equipe Brain Stimulation Group

2. Décomposition du projet (WBS) en Lots

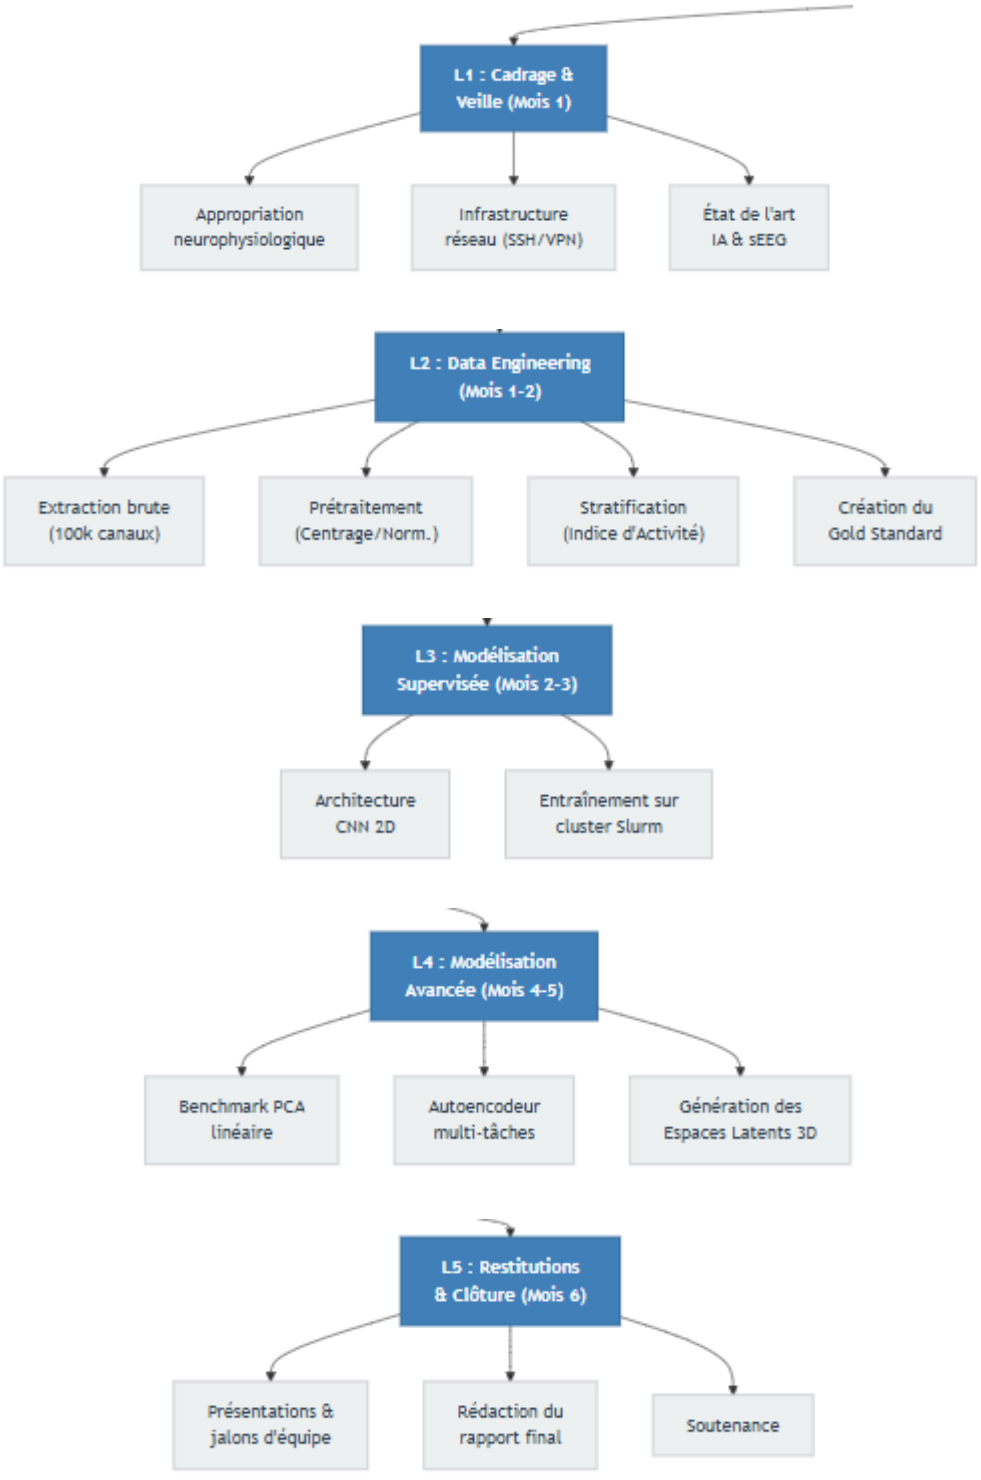
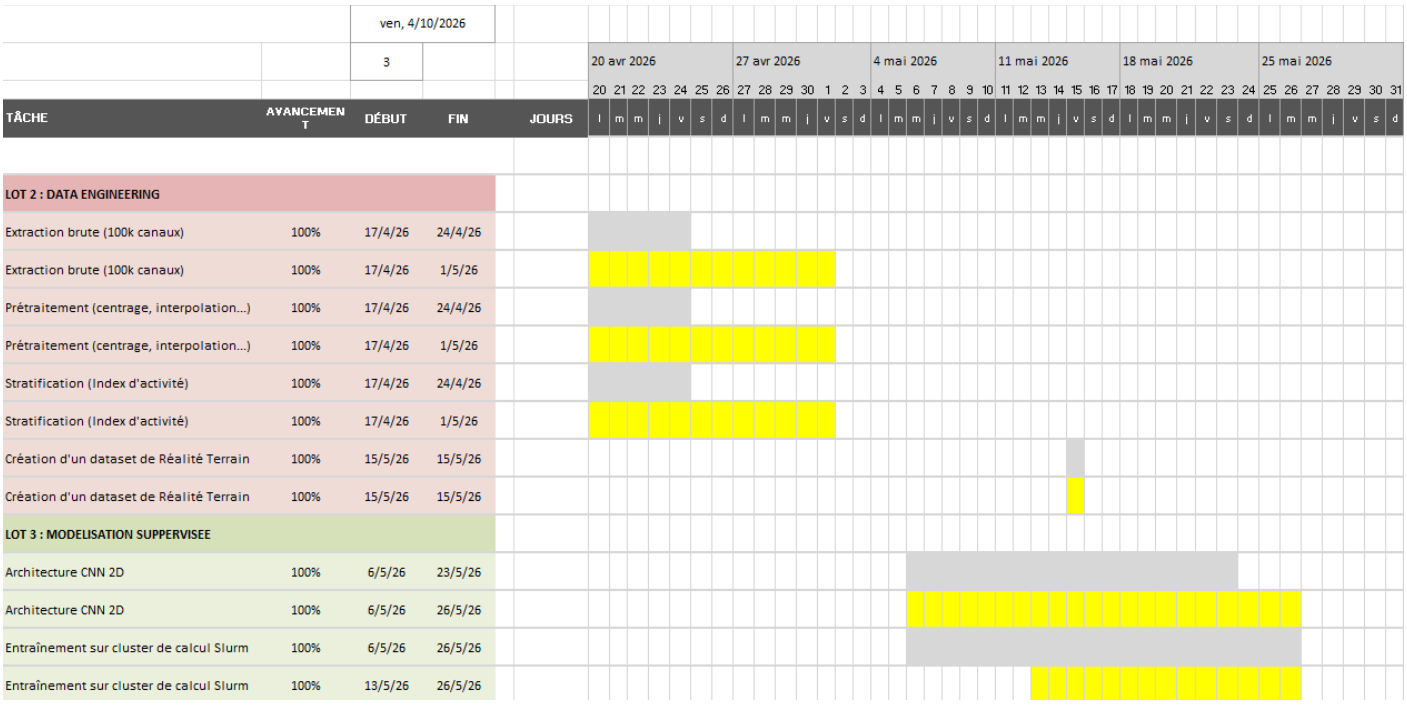


Figure 4.2 : Schéma raccourci du WBS

(*Visuel en annexe Figure A.2*)

3. Planification et écarts temporels (Prévisionnel vs Réel)



TÂCHE	AVANCEMENT	DÉBUT	FIN	JOURS
LOT 2 : DATA ENGINEERING				
Extraction brute (100k canaux)	100%	17/4/26	24/4/26	
Extraction brute (100k canaux)	100%	17/4/26	1/5/26	
Prétraitement (centrage, interpolation...)	100%	17/4/26	24/4/26	
Prétraitement (centrage, interpolation...)	100%	17/4/26	1/5/26	
Stratification (Index d'activité)	100%	17/4/26	24/4/26	
Stratification (Index d'activité)	100%	17/4/26	1/5/26	
Création d'un dataset de Réalité Terrain	100%	15/5/26	15/5/26	
Création d'un dataset de Réalité Terrain	100%	15/5/26	15/5/26	
LOT 3 : MODELISATION SUPPERVISEE				
Architecture CNN 2D	100%	6/5/26	23/5/26	
Architecture CNN 2D	100%	6/5/26	26/5/26	
Entraînement sur cluster de calcul Slurm	100%	6/5/26	26/5/26	
Entraînement sur cluster de calcul Slurm	100%	13/5/26	26/5/26	

Figure 4.3 : Diagramme de Gantt comparatif prévisionnel vs réel : *extrait de deux lots, en gris la prévision et en jaune la réalité terrain.*

Analyse du Chemin Critique et des Écarts Temporels

La confrontation entre le planning initialement envisagé et le déroulement effectif du stage met en évidence le rôle central du Lot 2 (Ingénierie des données) en tant que chemin critique du projet. Estimée à quelques semaines, cette phase a nécessité un investissement temporel nettement supérieur. Ce glissement s'explique par la volumétrie massive et l'hétérogénéité des signaux sEEG bruts à traiter. L'exigence de précision notamment l'extraction des fenêtres temporelles à la milliseconde près et l'interpolation des fréquences d'échantillonnage a généré une charge de calcul très importante. Cette extension de la phase de préparation a mécaniquement compressé la fenêtre dédiée aux premières itérations de modélisation. Néanmoins, cet écart a été intégralement pallié en fin de projet par l'automatisation des scripts d'entraînement sur le cluster de

calcul distribué de l'INS, permettant de paralléliser les tests des architectures d'intelligence artificielle.

4. Analyse des blocages et gestion des risques

Tout au long du développement, plusieurs obstacles techniques et théoriques ont nécessité un réajustement de la stratégie opérationnelle. Afin de sécuriser la livraison des modèles prédictifs, une démarche d'identification et d'atténuation des risques a été appliquée sur trois axes majeurs :

Saturation matérielle et limites d'infrastructure (Ressources Serveur/RAM) :

Risque et impact : la génération physique des jeux de données de très grande dimension ainsi que les entraînements des différentes architectures CNN testées saturaient la mémoire (RAM) et l'espace de stockage du serveur local, provoquant l'interruption des scripts de traitement et ralentissant ces deux tâches.

Action corrective : refonte des pipelines d'extraction de données via des traitements par lots (batch processing) et déportation de la charge d'entraînement vers le cluster distant.

Qualité des données et bruit de labellisation

Risque et impact : la base de données f-tract initiale comportait un bruit inhérent dû à une labellisation automatisée imparfaite. Entraîner les réseaux de neurones sur ces données risquait de biaiser l'apprentissage en reproduisant ces erreurs d'étiquetage.

Action corrective : déviation volontaire du planning initial pour concevoir un dataset "Réalité Terrain", validé par une révision experte manuelle garantissant la fiabilité des signaux de référence.

Courbe d'apprentissage théorique (Modélisation PCA)

Risque et impact : le développement du modèle de référence linéaire s'est heurté à la complexité à comprendre la théorie mathématique de l'Analyse en Composantes Principales appliquée aux séries temporelles, générant un ralentissement lors de la phase de modélisation avancée.

Action corrective : Investissement temporel ciblé dans la littérature d'algèbre linéaire (décomposition en valeurs singulières, variance expliquée) pour consolider les bases théoriques préalablement à l'implémentation algorithmique.

Chapitre 5 : Bilan Personnel et Professionnel

1. Bilan technique et scientifique (Hard skills)

Cette immersion de six mois au sein de l'Institut des Neurosciences et Systèmes a constitué un tremplin technique majeur, permettant de consolider et d'étendre les acquis théoriques de la formation d'ingénieur ISEN vers des applications de recherche concrètes. La complexité du projet a exigé une montée en compétence sur trois axes technologiques fondamentaux :

Ingénierie des données et traitement du signal biomédical

La manipulation de la base de données f-tract a nécessité le développement d'une expertise avancée en ingénierie des données massives. Le nettoyage, la standardisation et la stratification de signaux hétérogènes (plus de 100 000 canaux soit 1 million de fenêtres de stimulations) ont renforcé la maîtrise des librairies scientifiques Python telles que Pandas, NumPy et SciPy *[10]*. Le développement de scripts d'extraction à la milliseconde près et l'application de techniques d'interpolation complexes ont permis d'appréhender la réalité physiologique des signaux sEEG, aboutissant à la création d'un *dataset de réalité terrain* robuste, indispensable à l'évaluation des modèles.

Modélisation en Intelligence Artificielle et Deep Learning

Le cœur du projet a permis d'acquérir une maîtrise approfondie du framework PyTorch. Le développement d'architectures variées (réseaux de neurones convolutifs 2D, Autoencodeurs denses multi-tâches) a nécessité une compréhension fine de l'optimisation des fonctions de perte et de la rétropropagation. Parallèlement, l'implémentation de modèles de référence (Analyse en Composantes Principales) a consolidé les bases mathématiques en algèbre linéaire appliquées à la réduction de dimension pour l'analyse de séries temporelles complexes.

Infrastructures de calcul et bonnes pratiques de développement

La saturation précoce des ressources matérielles locales a imposé une transition vers des environnements de calcul haute performance (HPC). Le portage du code vers le cluster distribué de l'INS (géré par Slurm) a permis d'acquérir de solides compétences en environnement Linux, en parallélisation des tâches et en gestion des ressources (allocation de nœuds de calcul, optimisation de la RAM). Le flux de travail a été professionnalisé par l'utilisation systématique d'environnements virtualisés (Conda), du contrôle de version (Git/GitHub) et d'outils de développement distants (VS Code Remote SSH, Jupyter Lab). Environnements sur lesquels j'ai également appris différentes techniques de visualisations de données pratiques pour le data engineering ainsi que pour la visualisation de résultats de machine learning.

2. Bilan humain et méthodologique (Soft Skills)

Au-delà des compétences purement techniques, cette immersion de six mois au sein de l'Institut des Neurosciences et Systèmes a été un vecteur majeur de développement méthodologique.

Autonomie et gestion de la complexité

Évoluer dans un laboratoire de recherche exige une forte capacité d'adaptation. Contrairement à un environnement de développement logiciel classique, les cahiers des charges sont exploratoires et soumis aux aléas des données réelles. La gestion des contraintes matérielles liées au traitement d'un million de fenêtres et la nécessité de repenser l'architecture du projet ont forgé une véritable aptitude à la résolution de problèmes. Cette autonomie s'est traduite par la capacité à prendre des décisions techniques structurantes, comme la déviation du planning pour créer manuellement un jeu de données de référence face au bruit des labels initiaux.

Communication scientifique et travail collaboratif

L'intégration au sein d'une équipe pluridisciplinaire a nécessité d'ajuster le discours technique selon l'interlocuteur. La mise en place d'un suivi quotidien régulier avec un post-doc ayant de l'expérience dans le domaine a démontré l'importance de l'intelligence collective et de la critique constructive dans la validation physiologique des algorithmes. Par ailleurs, les restitutions formelles lors des revues de projet avec l'équipe de recherche ont permis d'affiner mes compétences en synthèse, en défense de choix algorithmiques et en vulgarisation scientifique.

3. Perspectives d'évolution et projet professionnel

Une vocation confirmée pour l'IA appliquée à la neurophysiologie

Cette immersion à l'interface entre l'ingénierie des données et la neurophysiologie a confirmé mon fort attrait pour le traitement des signaux biomédicaux complexes. L'application des architectures d'intelligence artificielle à des problématiques cliniques concrètes a été particulièrement formatrice et a donné tout son sens à ma spécialisation. Cette expérience m'a prouvé ma capacité à piloter des projets de bout en bout, de l'extraction des signaux jusqu'à la restitution des modèles de prédiction.

Deux trajectoires envisagées : Recherche et industrie

Fort de ce bilan très positif, mon projet professionnel s'articule aujourd'hui autour de deux voies complémentaires :

L'approfondissement par la recherche (Thèse) : L'aspect stimulant de l'investigation scientifique m'amène à considérer sérieusement la poursuite de travaux dans le même domaine ou similaires en doctorat. Une thèse me permettrait de continuer à innover sur l'analyse de signaux physiologiques et de repousser l'état de l'art des modèles actuels.

L’intégration en R&D dans le secteur privé : Parallèlement, je suis très attentif aux dynamiques d’industrialisation. Rejoindre le secteur privé me permettrait de valoriser mes compétences en intelligence artificielle sur des cycles de développement de produits de santé numériques, en bénéficiant de l’agilité, des ressources et des avantages inhérents à l’industrie.

En définitive, mon ambition est de rester au coeur de l’innovation technologique en santé, que ce soit par la création de nouveaux savoirs fondamentaux ou par leur transformation en solutions industrielles à grande échelle.

Conclusion

L'exploration fonctionnelle du cerveau par stéréo-électroencéphalographie (sEEG) génère des volumes massifs de données, au sein desquels l'identification des artéfacts de stimulation reste un défi majeur. La problématique centrale de ce projet consistait à déterminer dans quelle mesure l'intelligence artificielle pouvait automatiser et fiabiliser ce tri à grande échelle, en vue de remplacer et surpasser un système déterministe et d'accélérer les flux de travail cliniques.

La confrontation de trois stratégies de modélisation a permis d'apporter des réponses claires à cette question. Après avoir prouvé l'incapacité d'une approche linéaire (PCA) à séparer géométriquement les artéfacts des signaux physiologiques, nous avons démontré que l'apprentissage profond permettait d'extraire des représentations non linéaires discriminantes. L'architecture convolutive (CNN 2D) a offert la réponse prédictive la plus performante, surpassant l'algorithme historique en atteignant un taux de concordance de 84,60 % avec l'expertise médicale humaine. Parallèlement, l'exploration d'un Autoencodeur multi-tâches a répondu aux problématiques d'effet « boîte noire » inhérentes à l'IA, prouvant qu'un réseau pouvait modéliser la dynamique physique de l'onde pour construire un espace de décision interprétable cliniquement.

Néanmoins, ce travail exploratoire comporte certaines limites inhérentes à son cadre de développement. La qualité des apprentissages reste tributaire du « bruit de labellisation » présent dans le jeu de données d'entraînement initial. Bien que l'évaluation finale ait reposé sur une vérité terrain saine, les modèles se sont entraînés sur des données contenant les erreurs du précédent algorithme. Enfin, malgré des scores élevés, les modèles génèrent encore des faux positifs résiduels face à des signaux physiologiques présentant de fortes atypies morphologiques.

Ces limites dessinent naturellement les perspectives d'évolution de ce projet. À court terme, l'inférence du réseau convolutif sur l'intégralité des 13 millions de canaux de la base de données f-tract permettrait de valider son passage à l'échelle et d'évaluer sa robustesse face au bruit spécifique de chaque centre hospitalier. À plus long terme, l'intégration de ce pipeline prédictif au sein de l'équipe Brain Stimulation Group ouvrirait la voie à une classification des artéfacts en temps réel lors des acquisitions cliniques. En sécurisant la pureté des enregistrements sEEG, cette automatisation

contribuera directement à l'amélioration des modélisations de la connectivité cérébrale, au bénéfice de l'évaluation pré-chirurgicale des patients épileptiques.

Bibliographies et Sources

Neurophysiologie et Applications Cliniques (sEEG & CCEP) :

- [1] Borra, F. (2026). Bad channel definition: dichotomic channel classification [Document interne non publié]. *Institut des Neurosciences et Systèmes (INS)*.
- [2] David, O., Job, A.-S., De Palma, L., Hoffmann, D., Minotti, L., & Kahane, P. (2013). *Probabilistic functional tractography of the human cortex. NeuroImage, 80, 307-317.*
- [3] Matsumoto, R., et al. (2004). *Functional connectivity in the human language system: a cortico-cortical evoked potential study. Brain, 127(10), 2316-2330.*
- [4] Trebaul, L., Rudrauf, D., Job, A.-S., Mălîia, M. D., Popa, I., Barborica, A., Minotti, L., Mîndruță, I., Kahane, P., & David, O. (2016). *Stimulation artifact correction method for estimation of early cortico-cortical evoked potentials. Journal of Neuroscience Methods, 264, 94–102.*
- [5] Tuyisenge, V., Trebaul, L., Bhattacharjee, M., Chanteloup-Forêt, B., Saubat-Guigui, C., Mîndruță, I., Rheims, S., Maillard, L., Kahane, P., Taussig, D., & David, O. (2018). *Automatic bad channel detection in intracranial electroencephalographic recordings using ensemble machine learning. Clinical Neurophysiology, 129, 548–554.*
- [6] https://f-tract.eu/ - *site web du projet f-tract*

Ingénierie Mathématique et Apprentissage Profond (IA) :

- [7] Goodfellow, I., Bengio, Y., & Courville, A. (2016). *Deep Learning*. MIT Press.
- [8] Jolliffe, I. T. (2002). *Principal Component Analysis*. Springer.

Documentation Logicielle et Ressources Techniques :

- [9] Paszke, A., et al. (2019). *PyTorch: An Imperative Style, High-Performance Deep Learning Library*. Advances in Neural Information Processing Systems 32.
- [10] Python Software Foundation. *Python Language Reference*. https://docs.python.org/
- [11] AarnoStormborn. *Anomaly-detection-with-autoencoder*. Dépôt GitHub. https://github.com/AarnoStormborn/anomaly-detection-with-autoencoder

Annexes

1. Aperçus matrice des risques et WBS assemblé

Risque	Probabilité	Impact	Niveau de risque	Plan d'atténuation
Saturation matérielle et limite RAM du serveur local	4	4	16	Refonte des pipelines d'extraction des signaux via traitement par lots (batch processing). Migration immédiate des charges d'entraînement massif vers le cluster de calcul distribué de l'INS.
Bruit de labellisation de la base de données f-tract	4	3	12	Déviation volontaire du planning initial pour isoler un échantillon de 500 canaux. Co-validation d'une « Vérité Terrain » stricte avec l'expert clinique pour empêcher les modèles de reproduire les biais historiques.
Courbe d'apprentissage théorique (PCA et algèbre linéaire)	3	2	6	Investissement temporel ciblé dans la littérature mathématique (Décomposition en Valeurs Singulières). Sollicitation du mentorat technique quotidien pour sécuriser la compréhension avant l'implémentation Python.

Figure A.1 : Matrice des risques

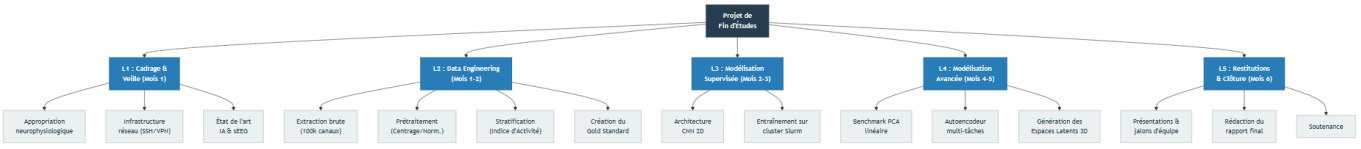


FIgure A.2 : Aspect WBS assemblé

2. Extrait du pipeline (script python) de traitement de données et Création des datasets

```python
def proportional_stratified_sampling(df_source, seed=42):
    """
    Balances the dataset across activity zones and hospital centers.
    Strategy: Local balance in Zone 2 + Proportional density for Good channels.
    """
    df = df_source[df_source['number_of_events'] >= 11].copy()

    # Extract hospital code (e.g., 0004GRE -> GRE)
    df['center'] = df['patient_id'].apply(lambda x: re.search(r'([A-Z]{3})', str(x)).group(1) if re.search(r'([A-Z]{3})', str(x)) else "UNK")

    Z2_MIN, Z2_MAX = 0.0, 2.0
    N_BINS_Z2 = 20
    BIN_CAP, Z3_CAP = 2500, 5000

    bins_edges = [-np.inf] + list(np.linspace(Z2_MIN, Z2_MAX, N_BINS_Z2 + 1)) + [np.inf]
    df['bin_cat'] = pd.cut(df['activity_index'], bins=bins_edges)

    sampled_good_base, sampled_bad_base = [], []

    for interval, group in df.groupby('bin_cat', observed=False):
        if interval.right == np.inf:
            bad_idx = group[group['good_channel_refined'] == False].index
            take_z3 = min(len(bad_idx), Z3_CAP)
            if take_z3 > 0: sampled_bad_base.append(df.loc[bad_idx].sample(n=take_z3, random_state=seed))
            continue

        good_idx, bad_idx = group[group['good_channel_refined'] == True].index, group[group['good_channel_refined'] == False].index
        take = min(len(good_idx), len(bad_idx), BIN_CAP)
        if take > 0:
            sampled_good_base.append(df.loc[good_idx].sample(n=take, random_state=seed))
            sampled_bad_base.append(df.loc[bad_idx].sample(n=take, random_state=seed))

    df_good_base = pd.concat(sampled_good_base) if sampled_good_base else pd.DataFrame()
    df_bad_base = pd.concat(sampled_bad_base) if sampled_bad_base else pd.DataFrame()

    deficit = len(df_bad_base) - len(df_good_base)
    sampled_good_extra = []
    if deficit > 0:
        mask_z1z2 = df['activity_index'] <= Z2_MAX
        df_good_natural = df[(df['good_channel_refined'] == True) & mask_z1z2]
        total_natural = len(df_good_natural)
        available_good = df[(df['good_channel_refined'] == True) & (~df.index.isin(df_good_base.index))]

        for interval, group in df_good_natural.groupby('bin_cat', observed=False):
            if interval.right == np.inf or total_natural == 0: continue
            weight = len(group) / total_natural
            target_extra = int(np.floor(deficit * weight))
            avail_in_bin = available_good[available_good['bin_cat'] == interval]
            take_extra = min(target_extra, len(avail_in_bin))
            if take_extra > 0: sampled_good_extra.append(avail_in_bin.sample(n=take_extra, random_state=seed))

        df_extra = pd.concat(sampled_good_extra) if sampled_good_extra else pd.DataFrame()
        rem_def = deficit - len(df_extra)
        if rem_def > 0:
            still_avail = available_good[~available_good.index.isin(df_extra.index)]
            take_rem = min(rem_def, len(still_avail))
            if take_rem > 0: sampled_good_extra.append(still_avail.sample(n=take_rem, random_state=seed))

    df_good_final = pd.concat([df_good_base] + sampled_good_extra) if sampled_good_extra else df_good_base
    return pd.concat([df_good_final, df_bad_base]).reset_index(drop=False)
```

Figure A.3 : Fonction représentant l'algorithme de stratification dynamique :
Segmentations en intervalles, échantillonnage équilibré et compensation des classes

3. Quelques aperçus d'autres "Bad channels"

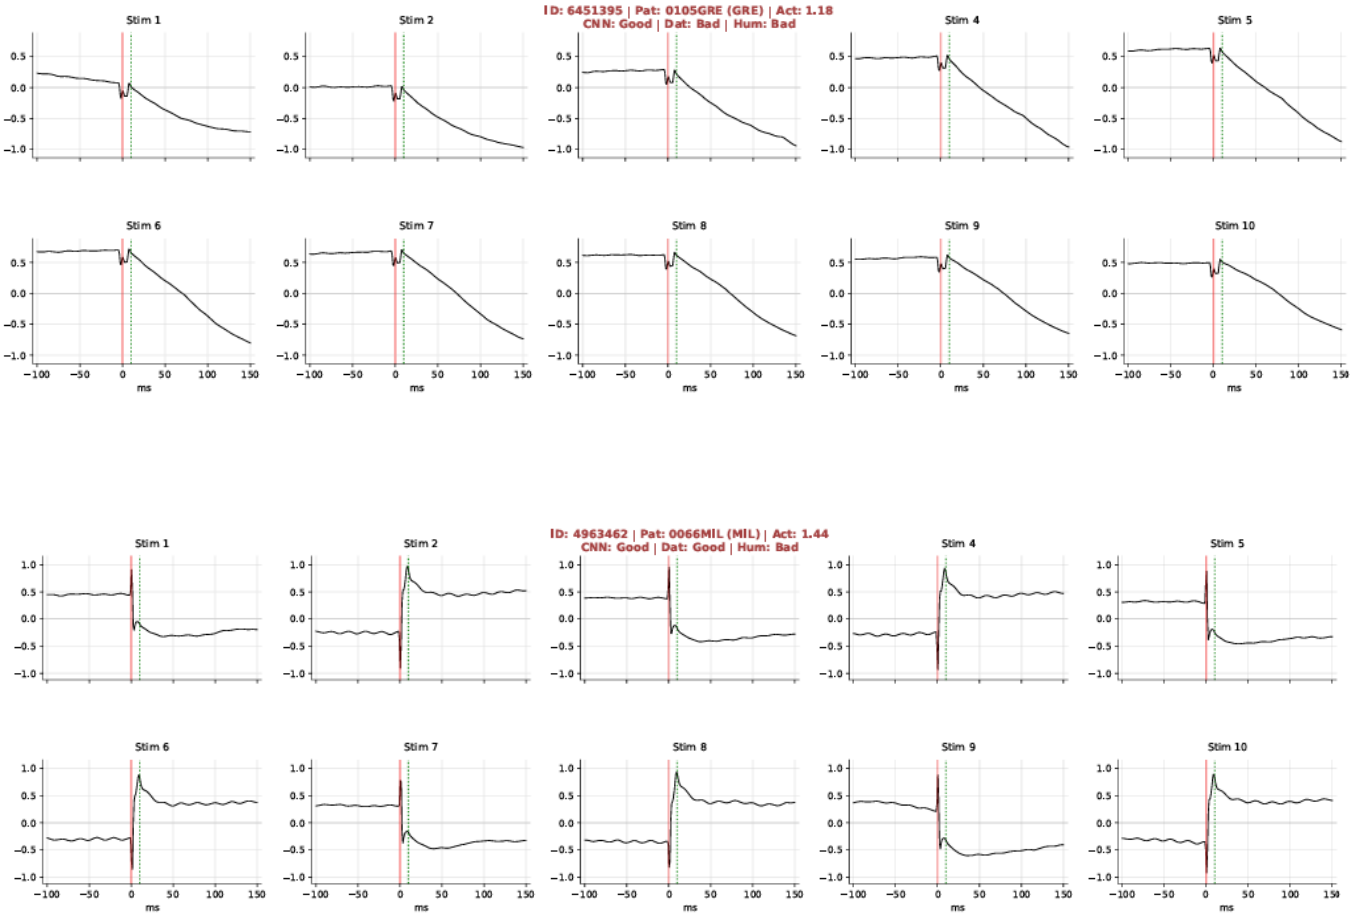


Figure A.4 : Artéfacts de nature biophysique et morphologique. *En haut : décharge capacitive lente masquant le signal. En bas : faux-semblant matériel imitant l'allure d'un potentiel évoqué.*

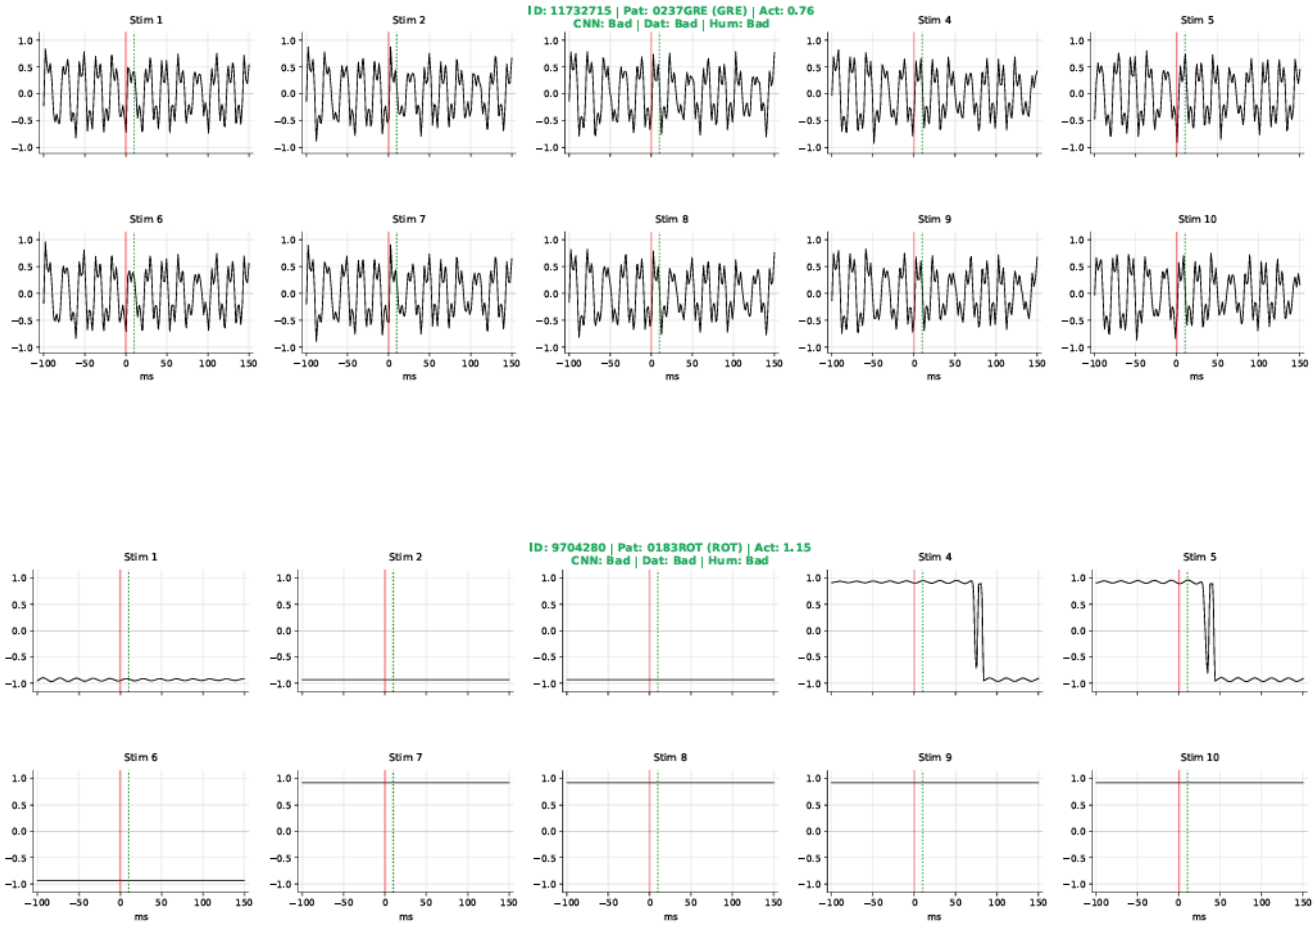


Figure A.5 : Artéfacts de nature matérielle. *En haut : contamination par un bruit périodique continu. En bas : saturation sévère de l'amplificateur avec décrochage de tension. (Note : L'axe des ordonnées est normalisé par division par l'écart-type, ne pas tenir compte de la couleur verte du titre).*

4. Utilisation de l'IA

Au cours de ce stage de fin d'études au sein de l'Institut des Neurosciences et Systèmes (INS), l'intelligence artificielle générative a été employée comme un assistant technique et méthodologique quotidien. L'objectif de cette démarche était d'optimiser les temps de développement pour se concentrer sur les enjeux scientifiques du traitement du signal biomédical. L'utilisation de cet outil s'est articulée autour de trois axes majeurs de l'ingénierie, tout en imposant l'exercice d'un esprit critique constant face à ses limites intrinsèques.

Prise en main de l'infrastructure et assistance au développement

L'intégration au sein de l'équipe de recherche a nécessité le déploiement de pipelines de calcul sur un serveur distant sous environnement Linux. L'IA a constitué un support technique essentiel pour appréhender cette infrastructure. Elle a facilité la formulation des commandes de navigation, la configuration stricte des environnements virtuels (Conda) et la gestion des conflits lors de l'installation des librairies scientifiques. Par la suite, l'outil s'est imposé comme un assistant de codage quotidien, permettant d'accélérer la syntaxe en Python, notamment pour la visualisation des fenêtres de stimulation et la manipulation des structures de données via Pandas et PyTorch.

Partenaire de réflexion stratégique et d'architecture

Au-delà de la simple génération de code, l'IA a été sollicitée lors des phases de conception algorithmique. Face à la problématique de la représentativité des données, elle a permis de confronter différentes stratégies pour concevoir la logique de stratification du dataset. De même, lors de la modélisation en apprentissage profond, l'outil a servi de partenaire de réflexion pour dimensionner l'architecture du réseau de neurones convolutifs (CNN) et structurer le goulot d'étranglement de l'Autoencodeur, en proposant des configurations qui ont ensuite été testées et ajustées empiriquement.

Support à la communication scientifique et à la rédaction

Dans le cadre de la rédaction de ce présent manuscrit, il a été utilisé ponctuellement pour la reformulation de certains paragraphes, l'optimisation de l'ordre des parties, et la génération de la syntaxe complexe des formules mathématiques en LaTeX.

Regard critique et limites technologiques

Si l'IA s'est révélée être un accélérateur de productivité, son utilisation intensive comme assistant de codage a rapidement mis en évidence ses limites face à la complexité d'un projet de recherche. L'outil gère difficilement le maintien d'un contexte global sur de multiples scripts imbriqués. Face à la quantité d'informations techniques et à la spécificité des tenseurs manipulés, le modèle a régulièrement généré des "hallucinations", proposant des modifications de code incohérentes ou oubliant la logique architecturale précédemment mise en place.



5. Analyse DDRSE

Le déploiement de l'intelligence artificielle dans le domaine de la santé neurophysiologique soulève des enjeux systémiques qui dépassent le strict cadre de la performance mathématique. L'application de modèles d'apprentissage profond à l'analyse de signaux sEEG s'inscrit dans une démarche d'ingénierie responsable, nécessitant de concilier l'innovation médicale avec la sobriété numérique, l'éthique clinique et la protection des données.

Analyse des impacts environnementaux

L'entraînement de réseaux de neurones (Deep Learning) sur des séries temporelles à haute fréquence est par nature une activité fortement énergivore. L'exploitation du cluster de calcul haute performance (HPC) de l'INS implique une sollicitation massive des processeurs, entraînant une consommation électrique significative liée au traitement et au refroidissement des serveurs. Pour atténuer cette empreinte carbone, une démarche de sobriété numérique a été intégrée dès l'ingénierie préliminaire :

- **Efficience de l'apprentissage :** L'implémentation algorithmique de mécanismes de régulation, tels que l'*Early Stopping*, intervenu de manière optimale à l'itération 21, a évité la poursuite de l'entraînement qui devenait redondant. Cela préserve les cycles d'horloge processeur tout en empêchant le surapprentissage du modèle.
- **Optimisation de la donnée :** Au lieu de monopoliser l'infrastructure de calcul de manière aveugle sur l'intégralité des 13 millions de canaux de la base f-tract, la conception d'un pipeline de stratification a condensé l'apprentissage sur un échantillon géométriquement équilibré de 100 000 canaux. Cette approche garantit l'extraction maximale d'informations neurophysiologiques pour un coût énergétique minimal.

Analyse des impacts sociaux : l'IA comme levier de réallocation médicale

Sur le plan sociétal, ce projet répond à une problématique centrale de la clinique moderne : la surcharge cognitive des équipes médicales et scientifiques.

- **Réduction de la charge mentale :** Le tri manuel de dizaines de milliers de signaux électriques intracérébraux est une tâche chronophage, répétitive et naturellement sujette à la fatigue humaine. L'automatisation de ce processus par le réseau convolutif décharge l'équipe de ce nettoyage fastidieux. Les chercheurs et neurophysiologistes peuvent ainsi réallouer leur temps à des tâches à plus haute valeur ajoutée, notamment l'interprétation des matrices de connectivité et la préparation des bilans pré-chirurgicaux.
- **Standardisation inter-centres :** En construisant un classifieur robuste face à l'hétérogénéité des signaux provenant des 20 centres hospitaliers du réseau f-tract, ce projet participe à l'uniformisation de la qualité des traitements.

Analyse éthique et responsabilité algorithmique

L'intégration d'une aide à la décision algorithmique dans un protocole d'exploration pré-chirurgicale impose le respect strict du principe de non-malfaisance (ne pas nuire au patient).

- **Sécurité et prévention des biais :** Un modèle qui validerait à tort un canal massivement artéfacté, menacerait la pertinence de l'analyse clinique en aval. C'est pourquoi la validation de l'architecture s'est affranchie de la labellisation historique pour s'appuyer sur une "Vérité Terrain" indépendante. L'audit manuel conjoint de 500 canaux garantit que l'évaluation repose sur une expertise clinique indéniable, minimisant volontairement le risque de faux négatifs critiques.
- **Confidentialité et protection des patients :** L'ensemble des développements a été opéré sur des vecteurs de données intégralement pseudonymisés. L'absence d'informations d'état civil ou de métadonnées patient au sein des tenseurs de calcul garantit le respect inaliénable du secret médical, en conformité totale avec le

RGPD et les chartes éthiques de traitement de la donnée de l'INSERM.

Analyse des impacts économiques

Dans le contexte d'un institut public de recherche, l'optimisation des temps d'ingénierie possède une valeur économique directe. En structurant un code parallélisable et en virtualisant les environnements de déploiement, le projet a fluidifié l'utilisation du cluster partagé. Cette rigueur évite la saturation des ressources du laboratoire, garantissant la poursuite des autres travaux de recherche de l'INS sans nécessiter d'investissements matériels d'infrastructure supplémentaires.

6. Auto-évaluation des compétences

ISEN MÉDITERRANÉE | L'ÉCOLE DES INGÉNIEURS DU NUMÉRIQUE

Maison du Numérique et de l'Innovation - Place Georges Pompidou
83000 Toulon - France | Tél. 04 94 03 89 50 | www.isen-mediterranee.fr

AUTO-ÉVALUATION DES COMPÉTENCES VISÉES

DI GIOVANNI Célian étudiant en **ISEN5**
DP DispoNumérique Biomédical

B1 Analyser la problématique : contexte, exigences, contraintes (techniques, légales, éthiques, modèle économique, environnementales, cybersécurité)
Maitrisé

Commentaire :

B1 Rédiger le cahier des charges en tenant compte de la problématique
Maitrisé

Commentaire :

B1 Réaliser les plans de tests et la recette du projet
Maitrisé

Commentaire :

B1 Evaluer le retour d'expériences et le retour sur investissement
Partiellement maitrisé

Commentaire :

B1 Prendre en compte le cycle de vie d'un produit dans ses dimensions environnementales, écologiques et climatiques, ainsi que ses dimensions sociétales et éthiques
Partiellement maitrisé

Commentaire :

B1 Réaliser un état de l'art en anglais ou en français sur une thématique donnée en exploitant les documentations scientifiques et techniques des domaines de la physique, du traitement du signal et de l'information et de l'algorithmique
Parfaitement maitrisé

Commentaire :

B1 Intégrer les problématiques de propriété et de protection des données dans le cadre de manipulation d'informations rattachées aux personnes physiques
Maitrisé

Commentaire :

B2 Concevoir une architecture statique et dynamique d'un système répondant aux besoins
Parfaitement maitrisé

B2 Qualifier, dimensionner, sécuriser les flux et le stockage : volumétrie, montée en charge, scalabilité, cybersécurité
Maitrisé

Commentaire :

B2 Choisir et qualifier les technologies métiers adaptées au projet : méthodes et outils
Maitrisé

Commentaire :

B2 Développer, tester, qualifier et valider le système produit et ses composants logiciels avec les outils et selon les méthodologies choisies
Maitrisé

Commentaire :

B2 Rédiger une documentation technique en français ou en anglais
Parfaitement maitrisé

Commentaire :

B2 Traiter des informations en grand nombre avec des outils, des méthodes et des algorithmes appropriés : traitements statistiques, algorithmes d'apprentissage. Le cas échéant mettre au point des outils spécifiques de type intelligence artificielle, adapté aux situations embarquées ou autres
Maitrisé

Commentaire :

B2 Co-concevoir et expérimenter des dispositifs technologiques et des modèles d'affaires innovants
Maitrisé

Commentaire :

B3 Initialiser, planifier et démarrer un projet : découpage en tâches, planning, budgets, risques, qualité, approvisionnement (charte projet, plan de management)
Parfaitement maitrisé

Commentaire :

B3 Gérer l'exécution d'un projet : coût, délais, qualité, avancement des tâches, ressources internes et externes
Maitrisé

Commentaire :

B3 Clôturer les étapes d'un projet et le projet, surveiller et appliquer les mesures de correction
Maitrisé

Commentaire :

B3 Communiquer à l'écrit et l'oral, en français ou en anglais, avec les parties prenantes (équipes, clients, fournisseurs...)
Parfaitement maitrisé

Commentaire :

B3 Prendre en compte les enjeux et les besoins environnementaux et sociétaux
Partiellement maitrisé

Commentaire :

B3 Rejoindre, s'intégrer, animer et piloter une équipe, une organisation, une entreprise
Maitrisé

Commentaire :

B3 Intégrer les problématiques de relation au travail en particulier celles de la reconnaissance de la diversité, s'adapter aux usages, règles et procédures de l'entreprise (Connu)
Parfaitement maitrisé

Commentaire :

B3 Gérer l'évolution de ses compétences et de sa carrière à travers la connaissance de soi et ses expériences professionnelles (Connu)
Maitrisé

Commentaire :